


DÉPARTEMENT DE MATHÉMATIQUES ET INFORMATIQUE

Master d'Excellence en Intelligence Artificielle



RAPPORT DE PROJET DE FIN DE MODULE :

Python pour la Science des Données

Sujet :

Détection et mitigation des biais algorithmiques dans les modèles de prédiction du turnover des ressources humaines

Réalisé par :

ALOUANI Hajar

BOUSYF Wahiba

CHAABAN Malika

BOUSSAID Salama

Exposé le 2026 devant les membres de jury :

Pr. NOUH Said

Faculté des sciences Ben M'Sick

Encadrant

Dr. Taoufik AMZIL

Faculté des sciences Ben M'Sick

Co-Encadrant

Année Universitaire : 2025-2026

Remerciement

Nous remercions avant tout Dieu le Tout-Puissant de nous avoir accordé la volonté, la persévérance et la force nécessaires pour mener ce travail à son terme.

Nous adressons nos remerciements les plus sincères à notre encadrant, Pr. NOUH Said, pour son accompagnement constant, ses conseils éclairés, sa rigueur scientifique et sa disponibilité tout au long de ce projet. Son expertise a grandement enrichi notre démarche de recherche.

Nous exprimons également notre profonde gratitude à notre co-encadrant, Monsieur AMZIL Taoufik, pour ses remarques pertinentes, ses conseils constructifs, son soutien technique et sa bienveillance, qui ont été essentiels au bon déroulement de ce travail.

Nous tenons à remercier l'ensemble du corps professoral de la Faculté des Sciences Ben M'Sik, et plus particulièrement les responsables du Master d'Excellence en Intelligence Artificielle, pour la qualité de l'enseignement dispensé et l'encadrement reçu au cours de notre formation.

Enfin, nous adressons un grand merci à nos familles et à nos amis pour leur soutien moral indéfectible, leur compréhension et leurs encouragements constants tout au long de ce parcours, ainsi qu'à toute personne ayant contribué, de près ou de loin, à la réussite de ce projet.

Merci à tous et à toutes.

Abstract

In an increasingly competitive labor market, employee turnover prediction has become a strategic priority for organizations. While machine learning (ML) models trained on Human Resource Information Systems (HRIS) data offer promising predictive capabilities, they frequently inherit structural biases from historical data, leading to discriminatory outcomes against protected groups such as gender and marital status. This study develops a fairness-aware methodological framework to detect, measure, and mitigate algorithmic bias in turnover prediction models without sacrificing predictive performance. Using the IBM HR Analytics Employee Attrition & Performance dataset, we compare **Logistic Regression**, **Random Forest**, and **XGBoost** classifiers, applying fairness metrics via the IBM AI Fairness 360 (AIF360) library and bias mitigation techniques across the ML. The retained model, a balanced **Random Forest** classifier, achieves a minority-class precision of **50%** with a low false-positive rate and a global accuracy exceeding **71%**, while attaining satisfactory fairness levels (Disparate Impact = 1.029 and Statistical Parity Difference = 0.005 for marital status; Disparate Impact = 1.202 for gender). These results demonstrate that meaningful bias reduction is achievable without disproportionate loss of predictive accuracy, with implications for the responsible deployment of automated HR systems, particularly in the Moroccan labor market context.

Keywords: employee attrition, algorithmic bias, ML fairness, AI Fairness 360, HR analytics, reweighing, responsible AI.

Résumé

Dans un marché du travail de plus en plus compétitif, la prédiction du turnover est devenue une priorité stratégique pour les organisations. Si les modèles d'apprentissage automatique entraînés sur des données RH offrent des capacités prédictives prometteuses, ils héritent fréquemment des biais structurels présents dans les données historiques, pouvant engendrer des discriminations envers des groupes protégés tels que le genre ou la situation familiale. Cette étude développe un cadre méthodologique orienté équité pour détecter, mesurer et atténuer les biais algorithmiques dans les modèles de prédiction de l'attrition, sans sacrifier les performances prédictives. En s'appuyant sur le jeu de données « IBM HR Analytics Employee Attrition & Performance », plusieurs classificateurs sont comparés, **Régression Logistique**, **Forêt Aléatoire** et **XGBoost**, à l'aide de métriques d'équité implémentées via la bibliothèque IBM AI Fairness 360 (AIF360) et de techniques de mitigation appliquées à différents niveaux du pipeline, notamment le reweighing (prétraitement) et l'adversarial debiasing (traitement). Le modèle retenu, une Forêt Aléatoire à classes équilibrées, atteint une précision de **50 %** sur la classe minoritaire avec un faible taux de faux positifs et une exactitude globale supérieure à **71 %**, tout en satisfaisant les critères d'équité (Disparate Impact = 1,029 et Statistical Parity Difference = 0,005 pour la situation familiale ; Disparate Impact = 1,202 pour le genre). Ces résultats démontrent qu'une réduction significative des biais est atteignable sans perte disproportionnée de performance prédictive, avec des implications concrètes pour le déploiement responsable des systèmes RH automatisés, notamment dans le contexte du marché du travail marocain.

Mots-clés : attrition du personnel, biais algorithmique, équité en apprentissage automatique, AI Fairness 360, analytique RH, reweighing, IA responsable.

Table des matières

Liste des abréviations	7
Liste des figures.....	8
Liste des Tableau	11
Introduction Générale.....	1
Chapitre 1 : Contexte général	2
1. Introduction	2
2. Historique de la reconnaissance des biais algorithmiques : De la négation à la validation scientifique	2
3. Problématique et objectifs	3
3.1. Problématique.....	3
3.2. Objectifs	5
4. Conduit de projet	7
4.1. GANTT	7
4.2. Agile (Scrum).....	8
5. Conclusion.....	9
Chapitre 2 : État de l'Art	10
1. Introduction	10
2. Revue comparative des travaux sur les biais et l'équité.....	10
3. Tableau Comparatif des Travaux de Recherche	12
4. Analyse Comparatif des Travaux de Recherche.....	16
4.1. Analyse des types d'ensembles de données utilisés	16
4.2. Analyse des modèles et approches méthodologiques	17
4.3. Analyse comparative des performances	18
5. Limites des travaux existants et perspectives d'amélioration	18
6. Conclusion.....	19
Chapitre 3 : Traitement et Modélisation	20
1. Introduction	20
2. Exploration et prétraitement des données.....	20
2.1. Exploration des données.....	20
2.2. Prétraitement des données	20
2.3. Analyse exploratoire des variables	24
3. Ingénierie et sélection des caractéristiques.....	30
4. Analyse des biais	31
4.1. Le biais	31
4.2. Identification des biais.....	31
5. Évaluation des performances et analyse de l'équité des modèles :	33
5.1. Évaluation des performances des modèles :	33
5.2. Analyse de l'équité des modèles :	34

6. Phase d'optimisation du cycle Recherche et Développement (R&D) – Amélioration de la précision et correction de biais	38
6.1. Traitement du déséquilibre de classes	38
6.2. Optimisations avancées après rééquilibrage.....	45
6.3. Correction des biais algorithmiques par Reconditionnement (Reweighting)	52
7. Déploiement : Implémentation de l'Application RecrutIA	56
7.1. Environnement et pile technologique	56
7.2. Interface utilisateur.....	56
7.3. Mode 1 — Analyse automatique d'un CV PDF	57
7.4. Mode 2 — Saisie manuelle.....	60
7.5. Affichage des résultats	60
8. Conclusion.....	63
Conclusion Générale	65
Bibliographie:.....	66

Liste des abréviations

LFR : Learning Fair Representations.

FICO : Fair Isaac Corporation, la société qui a créé le modèle de notation.

RGPD : Règlement Général sur la Protection des Données.

UE : Union européenne.

ROC : Receiver Operating Characteristic.

HR : Human Resources.

IBM : International Business Machines Corporation.

ADASYN : Adaptive Synthetic Sampling (échantillonnage synthétique adaptatif)

AUC : Area Under the Curve (aire sous la courbe ROC)

CV : Cross-Validation (validation croisée)

DI : Disparate Impact (impact disparate)

EDA : Exploratory Data Analysis (analyse exploratoire des données)

ENN : Edited Nearest Neighbors (voisins les plus proches modifiés)

F1-score : moyenne harmonique de la précision et du rappel

GridSearchCV : Grid Search Cross-Validation (recherche par grille avec validation croisée)

IA : Intelligence Artificielle

IBM : International Business Machines

KNN : K-Nearest Neighbors (K plus proches voisins)

R&D : Recherche et Développement

RandomizedSearchCV : Randomized Search Cross-Validation (recherche aléatoire avec validation croisée)

RF : Random Forest (forêt aléatoire)

RH : Ressources Humaines

ROC : Receiver Operating Characteristic (caractéristique de fonctionnement du récepteur)

SMOTE : Synthetic Minority Over-sampling Technique (technique de sur-échantillonnage synthétique des minorités)

SMOTEENN : combinaison de SMOTE et Edited Nearest Neighbors

SMOTETomek : combinaison de SMOTE et Tomek Links

SPD : Statistical Parity Difference (différence de parité statistique)

SVM : Support Vector Machine (machine à vecteurs de support)

UML : Unified Modeling Language (langage de modélisation unifié)

XGBoost : eXtreme Gradient Boosting (gradient boosting extrême)

Liste des figures

Figure 1:Diagramme de Gantt de projet	7
Figure 2 : Comparaison des tailles des principaux jeux de données utilisés.	16
Figure 5: Panorama des approches méthodologiques recensées dans la littérature	17
Figure 6: Représentation du compromis entre performance prédictive et équité algorithmique.....	18
Figure 9: répartition des 35 variables du dataset IBM HR par type	21
Figure 10: Distribution de la variable cible Attrition	22
Figure 11: Une asymétrie positive sur la variable TotalWorkingYears	22
Figure 12: Boxplot du variable 'Age'	23
Figure 14: Boxplot du variable TotalWorkingYears	24
Figure 16: Pie chart du variable Genre	24
Figure 17: Pie chart du variable MaritalStatus	25
Figure 18: Pie chart du variable BusinessTravel	25
Figure 20DistanceFromHome selon le Statut d'Attrition.....	26
Figure 21: Age selon le Statut d'Attrition	26
Figure 23: TotalWorkingYears selon le Statut d'Attrition	27
Figure 25: Distribution du genre selon le Statut d'Attrition.....	27
Figure 24: Fréquence des voyages d'affaires selon le Statut d'Attrition	28
Figure 26: Le statut marital selon le Statut d'Attrition.....	28
Figure 27: Analyse Multivariée des variables continues clés avec la distinction attrition ..	29
Figure 29: Comparaison des méthodes de sélection de features	30

Figure 30: Représentation graphique de l'accuracy	34
Figure 31: Représentation graphique des métriques de performance.....	34
Figure 32 : RANDOM FOREST AVEC POIDS	40
Figure 33:Random forest avec SMOTE	40
Figure 34:SMOTETomek avec SVR et Régression logistique.....	41
Figure 35 : SMOTEENN avec SVR et Régression logistique	41
Figure 36:Comparaison globale des métriques par modèle et technique	44
Figure 37: Ajustement du seuil de décision.....	45
Figure 38:Optimisation des hyperparamètres de XGBoost.....	46
Figure 39:Combinaison de modèles par vote	47
Figure 40:ADASYN avec Random Forest optimisé	47
Figure 41:Optimisation manuelle du paramètre	48
Figure 42: Recherche aléatoire d'hyperparamètres pour Random Forest	49
Figure 43:Balanced Random Forest	49
Figure 44:Ensemble personnalisé de Random.....	50
Figure 45: graphique compare les trois métriques.....	51
Figure 47:Modèle retenu	52
Figure 48:graphique des Métriques d'équité et performance	55
Figure 50 : Page d'accueil — en-tête et sélection du mode	57
Figure 51 : Zone d'import du CV PDF avec boutons de CV exemples	57
Figure 52 : Barre de progression de l'extraction IA en temps réel.....	58
Figure 53 : Carte de profil du candidat et grille des 8 métriques ML	59

Figure 54 : Volet de correction manuelle des données extraites.....	59
Figure 55 : Formulaire de saisie manuelle des attributs du candidat.....	60
Figure 56 : Bandeau de score avec décision de recrutement.....	61
Figure 57 : Jauge Plotly et analyse forces/risques du profil	62
Figure 58 : Bandeau de recommandation finale avec grade.....	62
Figure 59 : Analyse narrative RH générée par Llama 3.3 70B.....	63

Liste des Tableau

Tableau 1 : Tableau Comparatif des Travaux de Recherche.....	13
Tableau 4: Résultat de l'identification de biais dans les données	32
Tableau 5: Evaluation de la performance des modèles.....	33
Tableau 6: : Identification des biais pour le modèle de la régression logistique	35
Tableau 7: Identification des biais pour le modèle Random Forest	35
Tableau 8: Identification des biais pour le modèle SVM	36
Tableau 9: Identification des biais pour le modèle Gaussian Naive Bayes	36
Tableau 10: Identification des biais pour le modèle KNN	37
Tableau 11: Identification des biais pour le modèle Gradient Boosting.....	37
Tableau 12: Identification des biais pour le modèle XGBoost.....	38
Tableau 13: Comparaison des performances sur la classe minoritaire (Attrition = 1)	42
Tableau 14: Tableau comparatif des techniques d'optimisation	51
Tableau 15: Métriques d'équité et performance après Reconditionnement	55
Tableau 16 : Dépendances principales de l'application RecrutIA.....	56

Introduction Générale

Dans un environnement professionnel marqué par une concurrence accrue et une pénurie de talents, la prédiction du turnover est devenue un enjeu stratégique majeur pour les organisations. Les départs volontaires engendrent des coûts considérables, pouvant atteindre jusqu'à deux fois le salaire annuel d'un employé selon la SHRM, sans compter l'impact sur la productivité et la culture d'entreprise. Face à ces défis, les entreprises s'appuient sur des modèles d'intelligence artificielle et d'apprentissage automatique pour analyser les données RH et identifier les profils à risque de départ, s'inscrivant ainsi dans la dynamique du *people analytics* qui transforme la fonction RH en discipline orientée données.

Cependant, ces modèles sont fréquemment entraînés sur des données historiques qui reflètent des inégalités structurelles, conduisant à des biais algorithmiques susceptibles de discriminer involontairement certains groupes protégés tels que le genre, l'âge ou le niveau d'études. Ces biais exposent les organisations à des risques éthiques et réglementaires significatifs, notamment au regard du RGPD en Europe et des législations antidiscriminatoires en vigueur au Maroc et aux États-Unis. Ce projet vise donc à développer un cadre méthodologique rigoureux pour détecter, quantifier et atténuer ces biais dans les modèles prédictifs d'attrition, en mobilisant le jeu de données IBM HR Analytics et des outils tels que la bibliothèque AIF360, tout en préservant la performance prédictive.

Ce rapport s'articule en trois chapitres. Le premier pose le cadre conceptuel et les enjeux de la problématique. Le deuxième dresse un état de l'art des travaux existants sur les biais algorithmiques et les stratégies de mitigation en apprentissage automatique appliqué aux RH. Le troisième présente les résultats expérimentaux et analyse l'efficacité comparée des différentes approches de correction.

Chapitre 1 : Contexte général

1. Introduction

Ce chapitre a pour objectif d'établir le cadre conceptuel et contextuel dans lequel s'inscrit ce projet de recherche. Il présente les fondements théoriques nécessaires à la compréhension des enjeux liés à la prédiction du turnover en ressources humaines, en mettant en évidence la complexité des facteurs qui influencent les départs volontaires et les difficultés associées à leur anticipation. Dans ce contexte, l'analyse prédictive et les modèles d'apprentissage automatique constituent des outils essentiels pour identifier les employés à risque et optimiser les stratégies de rétention. Toutefois, l'utilisation de ces modèles soulève des questions fondamentales concernant les biais algorithmiques et leurs conséquences potentielles en termes d'équité et de discrimination. Ce chapitre pose ainsi les bases théoriques et méthodologiques indispensables à la compréhension des objectifs du projet et prépare le terrain pour les chapitres suivants, dédiés à l'analyse des sources de biais, aux méthodes de détection, ainsi qu'à la conception et à l'évaluation des stratégies de mitigation proposées.

2. Historique de la reconnaissance des biais algorithmiques : De la négation à la validation scientifique

De nombreux chercheurs ne croyaient pas au concept de biais algorithmiques dans les modèles d'intelligence artificielle, bien qu'il soit intéressant de noter que les travaux pionniers de Joseph Weizenbaum au milieu du XXe siècle avaient déjà introduit le concept du (biais dans les programmes informatiques) [1]. Weizenbaum postulait que le biais pouvait provenir à la fois des données utilisées dans un programme, mais aussi de la manière dont le programme est codé, une idée qui semblait contredire la croyance en la neutralité objective des algorithmes. Cependant, au fil des décennies, des découvertes majeures, comme la mise en évidence de biais raciaux dans le système COMPAS de prédiction de récidive (2016) ou le rejet discriminatoire des femmes et des candidats à noms étrangers dans l'outil de recrutement d'Amazon (2018), ont confirmé que les modèles d'apprentissage automatique pouvaient, dans certaines conditions, perpétuer et amplifier des inégalités sociétales[2][3]. Ces avancées ont non seulement validé l'existence des biais algorithmiques, mais ont également ouvert la voie à une compréhension plus approfondie de leurs mécanismes et à des approches de détection et de mitigation innovantes.

Autrefois considérées comme des anomalies isolées, les manifestations de biais algorithmiques sont désormais reconnues, grâce à des recherches approfondies en équité algorithmique (fairness in machine learning), comme touchant la majorité des systèmes d'IA déployés dans des domaines sensibles[4][5]. Parmi celles-ci, les biais dans les modèles de prédiction du turnover (rotation du personnel, ou attrition) en ressources humaines (RH) et les outils de gestion des talents sont les plus fréquents et préoccupants. Il est à noter qu'il existe de nombreuses sources de biais distinctes, allant de biais de données historiques (sampling bias) à des biais de modélisation (model bias), en passant par des biais émergents lors du déploiement (feedback loops)[6], [7].

3. Problématique et objectifs

3.1. Problématique

Les biais algorithmiques dans les modèles de prédiction du turnover (ou attrition) en ressources humaines (RH) ne constituent pas de simples anomalies théoriques, mais des réalités opérationnelles documentées par de nombreuses études empiriques. Bien que les algorithmes d'apprentissage automatique soient souvent perçus comme neutres et objectifs, ils sont intrinsèquement influencés par les données historiques sur lesquelles ils sont entraînés, qui reflètent des inégalités structurelles du marché du travail. Des cas emblématiques, tels que l'outil de recrutement d'Amazon (2018) qui rejetait systématiquement les candidatures féminines en raison de patterns discriminatoires dans les données passées, ou les systèmes de prédiction de récidive comme COMPAS aux États-Unis (2016) affichant des biais raciaux, illustrent comment ces modèles peuvent perpétuer et amplifier des discriminations sociétales [2], [8]. Dans le contexte spécifique de la prédiction de l'attrition RH, les modèles analysent des variables comme l'ancienneté, le salaire, le genre ou l'origine ethnique, et peuvent ainsi générer des prédictions biaisées : par exemple, un turnover artificiellement élevé chez les femmes en raison de congés maternité historiques, ou chez les employés issus de minorités en lien avec des salaires inférieurs moyens. Ces biais, souvent invisibles au stade de la performance globale (précision, AUC-ROC), deviennent critiques lors du déploiement, entraînant des décisions injustes en matière de rétention et de gestion des talents[9].

Cette problématique prend une dimension particulière dans le contexte marocain et maghrébin, où les disparités de genre et socio-économiques persistent de manière structurelle. Selon la Banque Mondiale (2023), le taux d'emploi féminin au Maroc reste inférieur à 25 %,

tandis que les inégalités régionales et ethniques limitent l'accès équitable aux opportunités professionnelles, exacerbées par des facteurs culturels et réglementaires. Dans ce cadre, un modèle prédictif d'attrition non corrigé pourrait aggraver ces déséquilibres : par exemple, en sur-représentant les profils féminins ou issus de zones rurales comme « à risque de départ », sans tenir compte des biais systémiques (discrimination salariale, manque de promotions). De telles prédictions biaisées non seulement nuisent à la diversité inclusive au sein des organisations, mais exposent également les entreprises à des sanctions réglementaires, conformément au Code du Travail marocain et à la loi 09-08 sur la protection des données personnelles [10]. De plus, dans un marché du travail en pleine transition numérique, où les secteurs bancaires et technologiques à Casablanca adoptent massivement l'IA, l'absence de mitigation des biais risque de compromettre la confiance des employés et la compétitivité des entreprises.

La problématique centrale de ce projet est donc double et interconnectée. D'une part, la détection : comment identifier et quantifier les biais dans un modèle de prédiction d'attrition, au-delà des métriques traditionnelles de performance qui masquent les disparités pour les sous-groupes protégés (genre, âge, origine ethnique) ? Des outils comme les métriques d'équité via des bibliothèques telles qu'AIF360 s'avèrent essentiels, mais leur application au domaine RH nécessite une adaptation aux données sensibles et à la dynamique des effectifs [4]. D'autre part, la mitigation : comment atténuer ces biais sans dégrader significativement la précision prédictive ? Les techniques existantes – rééquilibrage des données (reweighting), régularisation adversariale (adversarial debiasing) ou post-traitement des prédictions (Fairlearn) – doivent être contextualisées aux contraintes RH, où la sensibilité des données impose une gouvernance éthique rigoureuse, alignée sur les normes internationales (RGPD) et locales.

Ce projet s'appuie précisément sur les échanges antérieurs de nos conversations, où nous avons posé les fondements conceptuels : revue de littérature sur les biais en ML, sélection du jeu de données « IBM HR Analytics Employee Attrition & Performance » pour des simulations réalistes, et explorations préliminaires de métriques de fairness. En se focalisant sur la prédiction et la détection de l'attrition – c'est-à-dire le départ volontaire d'un employé – tout en corrigeant les biais de manière exhaustive, ce travail vise à transformer les modèles RH en outils équitables, contribuant ainsi à une IA responsable au service de la gestion des talents.

3.2. Objectifs

Face aux enjeux identifiés dans la problématique, ce projet de recherche poursuit un objectif principal : développer et évaluer une approche méthodologique rigoureuse pour la détection et l'atténuation des biais algorithmiques dans les modèles de prédiction du turnover en ressources humaines. Il ne s'agit pas simplement d'appliquer des techniques existantes de manière générique, mais bien de les adapter et de les contextualiser aux spécificités du domaine RH, où les décisions fondées sur ces modèles ont des implications directes sur le parcours professionnel des individus. Cette ambition se décline en plusieurs objectifs spécifiques, complémentaires et hiérarchisés, qui structureront l'ensemble de notre démarche.

Le premier objectif consiste à réaliser une analyse approfondie des sources potentielles de biais dans le contexte particulier de la prédiction du turnover. Il s'agira d'examiner comment les biais historiques présents dans les pratiques de gestion RH, les biais de représentation dans les données collectées, les biais de mesure liés aux indicateurs de performance, ou encore les biais d'étiquetage dans la définition même du "départ volontaire", peuvent influencer les modèles prédictifs. Cette phase d'analyse conceptuelle est fondamentale car elle conditionne la pertinence des étapes ultérieures de détection et de correction. Elle permettra d'établir une typologie des biais pertinents pour notre domaine d'application et d'identifier les variables sensibles (genre, âge, origine ethnique, etc.) dont la prise en compte est cruciale du point de vue éthique et juridique.

Le deuxième objectif vise à sélectionner, implémenter et comparer différentes métriques d'équité adaptées à la problématique du turnover. La littérature en fairness-aware machine learning propose de nombreux indicateurs (disparate impact, demographic parity, equalized odds, equal opportunity, predictive parity, etc.), mais leur pertinence varie selon le contexte décisionnel. Nous analyserons ces différentes métriques à la lumière des spécificités de la prédiction RH, en distinguant notamment les approches fondées sur l'égalité des résultats de celles fondées sur l'égalité des chances. Cette étape aboutira à la sélection d'un ensemble cohérent de métriques permettant une évaluation multidimensionnelle de l'équité des modèles développés.

Le troisième objectif concerne la conception et l'évaluation comparative de stratégies de mitigation des biais. Nous explorerons trois grandes familles d'approches : les méthodes de

prétraitement (ré-échantillonnage, pondération, transformation des données), les méthodes d'apprentissage sous contraintes (régularisation, optimisation multi-objectifs intégrant des critères d'équité), et les méthodes de post-traitement (ajustement des seuils de décision, reclassification). Pour chacune de ces approches, nous évaluerons leur efficacité à réduire les biais identifiés, leur impact sur la performance prédictive globale, et leur facilité d'implémentation dans un contexte opérationnel RH. L'objectif n'est pas d'identifier une solution universelle, mais plutôt de comprendre les compromis associés à chaque stratégie et de proposer des lignes directrices pour leur choix en fonction des priorités organisationnelles.

Le quatrième objectif, plus appliqué, consiste à développer un prototype d'outil d'audit des biais algorithmiques spécifiquement conçu pour les modèles de prédiction du turnover. Cet outil permettrait aux praticiens RH et aux data scientists de diagnostiquer facilement la présence de biais dans leurs modèles, de visualiser les disparités entre groupes, et d'explorer l'impact de différentes stratégies de correction. Au-delà de sa fonction technique, cet outil vise à favoriser une culture de l'équité algorithmique au sein des organisations en rendant accessibles et interprétables des concepts souvent perçus comme complexes et abstraits.

Enfin, le dernier objectif, transversal à l'ensemble du projet, est de formuler des recommandations pratiques et opérationnelles à destination des professionnels RH et des équipes data. Ces recommandations couvriront l'ensemble du cycle de vie d'un modèle prédictif : depuis la collecte et la préparation des données, en passant par le choix des algorithmes et des métriques d'évaluation, jusqu'au déploiement et au suivi continu des modèles en production. Elles intégreront également une dimension juridique, en proposant des pistes pour documenter la conformité des modèles avec les exigences du RGPD et du droit du travail en matière de non-discrimination.

En poursuivant ces objectifs, ce projet aspire à contribuer à l'émergence d'une IA RH plus responsable, où la quête de performance prédictive ne se fait pas au détriment de l'équité et de la justice sociale. Il s'inscrit dans une démarche de recherche appliquée, soucieuse de produire à la fois des avancées conceptuelles et des outils concrets utiles aux praticiens.

4. Conduit de projet

Pour assurer la réussite de ce projet dans le délai imparti, nous avons adopté une organisation structurée combinant planification temporelle et gestion itérative. Le projet est planifié à l'aide d'un diagramme de Gantt, permettant de visualiser les tâches principales, leur durée et les livrables associés. Parallèlement, nous suivons la méthodologie Agile (Scrum), qui facilite la répartition des tâches en sprints courts, favorise la collaboration entre les membres de l'équipe et permet une adaptation continue face aux imprévus. Cette double approche garantit un suivi précis et une exécution efficace du projet, tout en maintenant la flexibilité nécessaire pour ajuster les priorités au fur et à mesure de l'avancement.

4.1. GANTT

Le diagramme de Gantt permet de représenter visuellement le déroulement du projet, en mettant en évidence les tâches principales, leur durée et les livrables associés. Il fournit une vue d'ensemble claire de la planification temporelle et des dépendances entre les différentes étapes, facilitant ainsi le suivi de l'avancement et la coordination au sein de l'équipe.

Le diagramme de Gantt présenté ci-dessus illustre la planification temporelle détaillée du projet qui s'est déroulé sur une période totale de 30 jours, allant du 20 janvier 2026 au 20 février 2026, et comprend l'ensemble des tâches nécessaires à sa réalisation complète.




Figure 1: Diagramme de Gantt de projet

Les activités du projet ont couvert l'ensemble des étapes essentielles, notamment :

- La collecte et la synthèse des articles scientifiques sur les biais algorithmiques et l'équité en apprentissage automatique,
- La constitution et le prétraitement du jeu de données (analyse exploratoire, gestion des valeurs manquantes, normalisation et sélection des caractéristiques) en portant une attention particulière aux attributs sensibles,
- Le développement, l'entraînement et l'évaluation de modèles de prédiction du turnover,
- La comparaison des performances des modèles et l'optimisation des hyperparamètres,
- L'évaluation des biais à l'aide de métriques d'équité (disparate impact, égalité des chances, etc.) et la mise en œuvre de techniques de mitigation,
- La production des résultats, incluant les figures, tableaux et tableaux de bord interactifs,
- Ainsi que la rédaction, la mise en forme et la préparation de la présentation finale.

L'ensemble des tâches prévues a été réalisé avec succès, comme indiqué par les barres vertes représentant les tâches terminées, aboutissant à un taux de complétion de 100 %. Le diagramme met également en évidence le respect des délais initialement fixés, confirmant une planification efficace et une progression cohérente du projet jusqu'à sa finalisation.

4.2. Agile (Scrum)

La méthodologie Agile, et plus particulièrement Scrum, est utilisée pour organiser le travail en sprints courts et itératifs. Cette approche favorise la collaboration entre les membres de l'équipe, permet d'ajuster les priorités en fonction de l'avancement réel et assure une exécution flexible et efficace des tâches, tout en garantissant que chaque étape du projet est bien suivie et validée. La démarche s'est ainsi articulée autour de quatre sprints progressifs : le premier a posé les fondements scientifiques à travers une revue de littérature multi-sources sur les biais algorithmiques et l'équité en IA, ainsi qu'une évaluation initiale du jeu de données IBM HR Attrition ; le deuxième a été consacré au prétraitement des données, incluant l'analyse exploratoire, le nettoyage, l'ingénierie des variables et la séparation train/test, avec une attention particulière aux déséquilibres entre groupes protégés ; le troisième a porté sur le développement et l'évaluation comparative des modèles de prédiction du turnover, en combinant métriques de

performance classiques et métriques d'équité, et en expérimentant des techniques de mitigation aux trois niveaux du pipeline (prétraitement, in-processing et post-traitement) ; enfin, le quatrième sprint a finalisé le projet à travers la rédaction du rapport scientifique, le développement d'un prototype interactif Streamlit et la préparation de la soutenance, aboutissant à la livraison d'un système complet de détection et d'atténuation des biais algorithmiques, conforme aux exigences éthiques, techniques et académiques du domaine.

5. Conclusion

Ce premier chapitre a établi les fondements conceptuels du projet en situant la problématique à l'intersection du people analytics et de l'équité algorithmique. L'analyse des différentes sources de biais en contexte RH a mis en évidence la tension centrale de ce travail : concilier performance prédictive et fairness algorithmique, une question qui dépasse la seule dimension technique pour engager des enjeux éthiques, juridiques et sociaux. Pour y répondre, une démarche structurée a été définie, articulant analyse des biais, sélection de métriques d'équité, évaluation des stratégies de mitigation et formulation de recommandations opérationnelles. Il ressort de ce cadrage que l'équité algorithmique n'est pas une contrainte accessoire, mais une dimension constitutive de la légitimité et de la performance des modèles prédictifs RH, perspective qui guidera l'ensemble des chapitres suivants.

Chapitre 2 : État de l'Art

1. Introduction

Les systèmes de recrutement par IA améliorent l'efficacité des processus de sélection, mais restent sensibles aux biais des données d'entraînement et de conception, pouvant mener à des décisions discriminatoires envers des groupes protégés. Ce chapitre propose une revue de littérature sur la détection, l'évaluation et la correction de ces biais dans les applications RH, afin d'identifier les lacunes existantes et de justifier le développement d'un pipeline intégré couvrant ces trois dimensions sur des données RH réelles.

2. Revue comparative des travaux sur les biais et l'équité

Cette section présente une synthèse des travaux de recherche existants sur la détection et la correction des biais dans les systèmes d'intelligence artificielle appliqués au recrutement et à la gestion des ressources humaines.

Travaux connexes :

2.1. Fondements Théoriques de l'Équité Algorithmique

Dans leur article, **Dwork et al.**[11] formalisent le concept d'équité individuelle (des individus similaires doivent recevoir un traitement similaire) via une condition de Lipschitz appliquée aux fonctions de décision, nécessitant une métrique de similarité adaptée au contexte. Ils abordent également l'équité de groupe à travers la distance de Earthmover pour mesurer les écarts entre distributions, et démontrent qu'aucune définition unique de l'équité ne peut capturer l'ensemble des formes de discrimination. Ce cadre théorique constitue un fondement majeur des recherches ultérieures en équité algorithmique.

Zemel et al.[12] présentent LFR, un algorithme de prétraitement qui crée une représentation intermédiaire des données masquant l'appartenance aux groupes protégés tout en conservant le pouvoir prédictif. Le modèle optimise la parité statistique, la préservation de l'information et la précision de classification. Testé sur German Credit, Adult Income et Heritage Health, LFR réduit la discrimination à moins de 0,03 tout en maintenant une précision d'environ 82 % et une

prédiction du groupe protégé proche du hasard (~50 %). Cette méthode est efficace comme technique de mitigation prétraitement pour tout pipeline ML.

Dans l'étude de **Hardt et al.**[13] deux critères de post-traitement pour l'équité algorithmique sont proposés : les « Equalized Odds », qui imposent que les taux de vrais positifs et de faux positifs soient équivalents entre groupes, et l'« Equal Opportunity », qui ne requiert que l'égalité des taux de vrais positifs. La méthode consiste à ajuster les seuils de décision par groupe à l'aide de la programmation linéaire, sans nécessiter de réentraînement du modèle. Appliquée aux scores de crédit FICO en considérant la race comme attribut protégé, l'Equal Opportunity permet de conserver 92,8 % du profit maximum, contre 80,2 % pour l'Equalized Odds et 69,8 % pour la parité démographique. Cette approche de post-traitement peut être directement intégrée dans notre pipeline de correction des biais.

2.2. Études Appliquées : Biais dans les Systèmes RH et de Recrutement

Raghavan et al.[14] audient 18 outils d'évaluation algorithmique pour le recrutement et montrent que seulement 7 mentionnent l'impact différentiel et 3 la règle des 4/5. La méthode principale de débiaisage consiste à supprimer les variables corrélées aux attributs protégés (Disparate Learning Processes), similaires aux représentations équitables de Zemel et al. Les auteurs soulignent des problèmes critiques : biais dans les variables cibles, biais de sélection et opacité des modèles d'apprentissage profond. Cette étude justifie l'importance de la transparence et de l'audit systématique des biais.

Oladipupo et al.[15] démontrent qu'une haute performance prédictive ne garantit pas l'équité algorithmique. Sur l'IBM HR Analytics dataset, leur classificateur Random Forest atteint 92,3 % de précision et un AUC de 0,97, mais révèle des disparités genrées marquées : les femmes obtiennent de meilleurs résultats sur toutes les métriques (précision globale : 95,30 % vs 87,01 % ; précision positive : 96,15 % vs 89,01 % ; rappel : 95,42 % vs 80,20 %). Malgré l'application du rééchantillonnage SMOTE-Tomek et l'évaluation via trois critères d'équité, l'étude conclut que la robustesse statistique globale peut masquer des biais systémiques au niveau des sous-groupes, entraînant des risques organisationnels concrets : décisions injustes, perte de confiance des employés et affaiblissement des initiatives de diversité.

2.3. Cadres Juridiques et Réglementaires

Rigotti & Fosch-Villaronga[16] démontrent, via une revue de littérature exhaustive, que l'équité dans le recrutement par IA reste mal définie malgré une attention réglementaire croissante. Les systèmes d'IA perpétuent la discrimination et génèrent des perceptions divergentes entre candidats et professionnels RH. Le cadre juridique européen présente des lacunes notables : le droit anti-discrimination ignore l'intersectionnalité, le RGPD crée une tension entre protection des données et détection des biais, et la loi sur l'IA manque d'intégration avec les dispositifs existants. Les auteurs plaident pour des approches interdisciplinaires et participatifs traitant les asymétries de pouvoir et ancrant l'équité dans les droits fondamentaux, au-delà de la simple conformité algorithmique..

Chang[17] examine le biais de genre dans l'outil de recrutement IA d'Amazon via une approche qualitative . L'étude révèle un biais systématique en faveur des hommes, induit par des mots-clés genrés, se traduisant par un taux d'emploi deux fois supérieur (40 % vs 20 %). L'auteur recommande quatre leviers correctifs : transparence des critères de sélection, objectifs de diversité responsabilisants, formation aux biais inconscients et sensibilisation des femmes dans le secteur technologique, concluant que des interventions organisationnelles concrètes sont indispensables pour un recrutement équitable.

3. Tableau Comparatif des Travaux de Recherche

Pour situer notre étude dans le contexte des avancées récentes en correction des biais par intelligence artificielle, nous présentons ci-dessous un tableau comparatif des travaux les plus marquants publiés entre 2011-2026. Ce tableau synthétise les informations clés suivantes :

- **Référence** : Références des études citées.
- **Domaine** : précise le contexte ou l'application étudiée.
- **Ensemble de Données (Dataset)** : décrit le jeu de données utilisé pour l'étude.
- **Modèle** : indique les modèles d'intelligence artificielle ou algorithmes utilisés.
- **Attribut Protégé** : liste les caractéristiques sensibles ou protégées selon lesquelles le biais peut apparaître (genre, âge, race, handicap, etc.).
- **Métriques d'Équité** : détaille les mesures utilisées pour évaluer l'équité du modèle.
- **Résultats Clés** : synthétise les principales conclusions de l'étude.
- **Approche de Mitigation** : décrit les techniques ou stratégies mises en œuvre.
- **Limitations** : liste les contraintes, limites méthodologiques ou lacunes de l'étude.

Tableau 1 : Tableau Comparatif des Travaux de Recherche

Reference	Domaine	Ensemble de Données	Modèle	Attribut Protégé	Métriques d'Équité	Résultats Clés	Approche de Mitigation	Limitations
Zemel et al. (2013)	Équité ML générale	German Credit, Adult Income, Heritage Health	LFR (représentation apprise basée sur des prototypes) + Régression logistique	Âge, Genre	Parité statistique, Équité individuelle (cohérence)	Discrimination < 0,03 sur Adult ; Accuracy ~82 % ; Prédiction du groupe ~50 % (aléatoire)	Prétraitement : apprend des représentations intermédiaires masquant les attributs protégés	Suppose classification linéaire ; ne gère pas les attributs intersectionnels ; nécessite K prototypes prédéfinis
Dwork et al. (2011)	Équité ML générale	Cadre théorique (pas de dataset empirique)	Théorique (cadre Lipschitz)	Générique (tout attribut protégé)	Équité individuelle (condition Lipschitz), Parité statistique (distance Earthmover)	Impossibilité démontrée d'avoir simultanément équité et précision parfaite dans certaines conditions	Mapping basé sur la similarité : individus similaires reçoivent des résultats similaires via une métrique spécifique à la tâche	Nécessite une métrique de similarité externe ; pas de généralisation aux données non vues ; uniquement théorique
Hardt et al. (2016)	Équité ML générale	FICO Credit Score (TransUnion,	Post-traitement sur tout	Race (Asiatique, Blanc,	Equalized Odds, Equal Opportunity,	Equal Opportunity : 92,8 % profit conservé ;	Post-traitement : ajuste les seuils spécifiques aux	Ignorant la structure causale ; peut nécessiter des

Reference	Domaine	Ensemble de Données	Modèle	Attribut Protégé	Métriques d'Équité	Résultats Clés	Approche de Mitigation	Limitations
		~300k enregistrements)	classificateur de base (agnostique au modèle)	Hispanique, Noir)	Parité démographique	Equalized Odds 80,2 % ; Parité démographique 69,8 % vs non contrainte	groupes via programmation linéaire sur les courbes ROC	seuils aléatoires ; limité à la classification binaire
Raghavan et al. (2020)	IA pour le recrutement (audit industriel)	18 sites de fournisseurs (analyse qualitative, pas de dataset ML)	Divers (spécifique au fournisseur : NLP, analyse vidéo, gamification, classificateurs ML)	Race, Genre, Âge, Handicap	Règle des 4/5 (impact défavorable), Validité différentielle	7/18 fournisseurs seulement discutent de l'impact défavorable ; 3 mentionnent la règle des 4/5 ; transparence limitée	Suppression des variables corrélées aux attributs protégés (DLP) puis retest	Données publiques seulement ; pas d'accès aux algorithmes ; focus légal US ; pas d'évaluation quantitative
Oladipupo et al. (2026)	IA RH / Attrition des employés	IBM HR Analytics (Kaggle) – 1 470 enregistrements, 35 attributs	Random Forest (avec GridSearchCV, CV 5-fold)	Genre (Homme/ Femme)	Equal Accuracy, Parité démographique, Equal Opportunity	Global : 92,3 % acc, AUC 0,97 ; Homme : 87 % acc, 80 % recall ; Femme : 95 % acc, 95 % recall	SMOTE-Tomek pour déséquilibre des classes ; recommande post-traitement equalized odds (non implémenté)	Genre uniquement ; dataset simulé ; pas d'analyse SHAP ; correction des biais non appliquée ; snapshot statique

Reference	Domaine	Ensemble de Données	Modèle	Attribut Protégé	Métriques d'Équité	Résultats Clés	Approche de Mitigation	Limitations
Rigotti & Fosch-Villaronga (2024)	Recrutement IA (revue juridique/politique)	N/A (revue de littérature)	N/A (analyse légale et réglementaire)	Genre, Race, Âge, Handicap, Intersectif	Équité procédurale (pertinence, cohérence, objectivité, opportunité de performance)	Équité définie de manière fragmentaire dans la loi UE ; tension RGPD Art. 9 ; IA Act classe le recrutement comme haut risque	Approche pluridisciplinaire : conformité légale + métriques d'équité + design participatif + DPIA	Pas de validation empirique ; centré UE ; pas de métriques quantitatives ; cadre conceptuel uniquement
Chang (2023)	Recrutement IA (étude de cas)	Qualitatif (30 interviews + focus groups)	Algorithme de sélection de CV d'Amazon (NLP propriétaire)	Genre	Écart de taux d'emploi (qualitatif), analyse de pénalisation des mots-clés	Hommes 40 % vs Femmes 20 % taux d'emploi ; algorithme pénalisait les mots-clés associés aux femmes	Recommandations : transparence, objectifs de diversité, mentorat, sensibilisation élargie	Échantillon réduit (n=30) ; données auto-déclarées ; outil Amazon discontinué ; pas d'implémentation technique

4. Analyse Comparatif des Travaux de Recherche

4.1. Analyse des types d'ensembles de données utilisés

Les premiers travaux en équité algorithmique reposent principalement sur des jeux de données publics devenus standards dans la littérature en apprentissage automatique. C'est notamment le cas des travaux de **Rich Zemel et al**, qui utilisent le German Credit, le Adult Income ainsi que le Heritage Health Ensemble de données. Ces bases de données présentent des caractéristiques communes : une taille modérée, des tâches de classification binaire et des attributs protégés simples tels que l'âge ou le genre. Leur utilisation permet une comparaison standardisée des méthodes proposées, facilitant la reproductibilité scientifique. Toutefois, ces jeux restent limités en termes de complexité réelle, notamment en ce qui concerne la prise en compte de dynamiques organisationnelles ou d'interactions intersectionnelles entre plusieurs attributs sensibles.




Figure 2 : Comparaison des tailles des principaux jeux de données utilisés.

Une avancée significative vers des données plus réalistes est observée dans les travaux de **Moritz Hardt et al**, qui exploitent des données industrielles issues du système de notation de crédit FICO, comportant environ 300 000 enregistrements. Contrairement aux jeux académiques classiques, ces données reflètent des distributions réelles et des déséquilibres structurels observés dans le secteur financier, avec la race comme attribut protégé principal. Cette utilisation marque un tournant vers des évaluations d'équité à grande échelle et dans des contextes socio-économiques à fort impact.

Enfin, certains travaux ne mobilisent aucun jeu de données empirique structuré. Les recherches de **Cynthia Dwork et al** proposent un cadre purement théorique fondé sur la condition de Lipschitz pour formaliser l'équité individuelle. De même, les analyses de **Francesca Rigotti et Eleni Fosch-Villaronga** adoptent une approche juridique et réglementaire, tandis que **Chang** s'appuie sur une méthodologie qualitative fondée sur 30 entretiens et groupes de discussion. Ces travaux enrichissent la compréhension conceptuelle et institutionnelle de l'équité, mais ne permettent pas une validation quantitative des performances algorithmiques.

4.2. Analyse des modèles et approches méthodologiques

Les approches de la littérature se répartissent entre prétraitement, post-traitement et analyses conceptuelles. **Zemel et al.** introduisent Learning Fair Representations, une méthode de prétraitement qui apprend des représentations intermédiaires masquant les attributs protégés tout en préservant l'information prédictive, mais repose sur des prototypes prédéfinis et un classificateur linéaire, limitant sa généralisation. **Hardt et al.** proposent une approche de post-traitement agnostique au modèle, imposant des contraintes d'Equalized Odds ou d'Equal Opportunity via l'ajustement des seuils décisionnels par groupe, formulé en programmation linéaire sur les courbes ROC, applicable à tout modèle binaire, sans modifier sa structure interne. **Oladipupo et al.** privilégient la performance prédictive avec un Random Forest optimisé par GridSearchCV, validation croisée à cinq plis et rééchantillonnage SMOTE-Tomek, suivi d'un audit d'équité a posteriori. Enfin, **Raghavan, Rigotti et Chang** adoptent des méthodologies non techniques, audits industriels, analyses documentaires et études de cas, déplaçant le débat vers la gouvernance, la conformité réglementaire et la justice procédurale.




Figure 3: Panorama des approches méthodologiques recensées dans la littérature

4.3. Analyse comparative des performances

Les résultats obtenus dans ces études révèlent un constat central : une performance prédictive élevée ne garantit pas l'équité entre groupes protégés. **Zemel et al** atteignent une précision d'environ **82 %** sur Adult Income tout en réduisant la discrimination statistique à moins de 0,03. **Hardt et al.** montrent qu'en imposant l'Equal Opportunity, environ **92,8 %** du profit initial peut être conservé, tandis que l'imposition de la parité démographique entraîne une perte plus importante. **Oladipupo et al.** rapportent une précision globale de **92,3 %** et un AUC de **0,97**, mais observent des disparités significatives entre hommes et femmes en termes de recall et d'accuracy.




Figure 4: Représentation du compromis entre performance prédictive et équité algorithmique.

5. Limites des travaux existants et perspectives d'amélioration

La littérature sur l'équité algorithmique en RH présente trois catégories de limites. Sur le plan des données, les études s'appuient majoritairement sur des jeux de données simulés ou anciens (IBM HR Analytics, Adult, German Credit) ne reflétant pas la complexité organisationnelle réelle, et analysent rarement plusieurs attributs protégés simultanément, ignorant ainsi les effets intersectionnels. Sur le plan méthodologique, les approches existantes souffrent de contraintes intrinsèques, métrique de similarité difficilement définissable chez Dwork, ignorance de la structure causale chez Hardt, dépendance à une structure linéaire chez Zemel, et le compromis équité-performance demeure non résolu. Enfin, sur le plan de l'implémentation et de la gouvernance, Raghavan souligne le manque de transparence des fournisseurs quant aux impacts défavorables, Chang pointe l'absence de corrections malgré les

biais identifiés, et Rigotti met en évidence la fragmentation des définitions juridiques de l'équité ainsi que la tension persistante entre protection des données et détection des discriminations.

6. Conclusion

L'analyse comparative souligne que l'équité algorithmique est un problème multidimensionnel qui ne peut se réduire à une simple optimisation mathématique. Si les travaux théoriques ont formalisé des définitions rigoureuses de la fairness et les approches algorithmiques ont proposé des mécanismes de mitigation à différents niveaux du pipeline, les contributions existantes demeurent souvent fragmentées : les solutions techniques ne garantissent pas une justice procédurale réelle, les analyses réglementaires manquent d'ancrage empirique, et la tension entre performance prédictive et équité reste insuffisamment résolue. Une approche intégrée s'impose donc, combinant modélisation sous contraintes d'équité, audit empirique systématique des performances inter-groupes et alignement avec les exigences réglementaires et éthiques, afin de produire des systèmes d'IA à la fois performants, explicables et socialement responsables.

Chapitre 3 : Traitement et Modélisation

1. Introduction

Ce chapitre constitue le cœur opérationnel de cette étude et couvre l'ensemble du cycle de vie du modèle, depuis la donnée brute jusqu'au déploiement final. Dans un premier temps, le jeu de données IBM HR Analytics Employee Attrition est présenté et analysé dans sa structure, ses distributions et ses spécificités, suivi d'une phase de prétraitement rigoureux produisant un dataset propre, encodé et normalisé, puis d'une sélection multi-méthodes des variables les plus informatives. Dans un second temps, l'analyse des biais est conduite via la bibliothèque IBM AIF360, permettant de détecter et quantifier les disparités entre groupes protégés avant d'appliquer les techniques de mitigation appropriées. S'ensuit la phase d'entraînement et d'optimisation des modèles de prédiction du turnover, évalués selon un double critère de performance prédictive et d'équité algorithmique. Le chapitre s'achève par le déploiement d'un prototype interactif développé sous Streamlit, offrant une interface accessible pour l'audit et la visualisation des résultats du système.

2. Exploration et prétraitement des données

2.1. Exploration des données

Le jeu de données utilisé dans cette étude est le [IBM HR Analytics Employee Attrition Dataset](#), mis à disposition publiquement par IBM via la plateforme **Kaggle**. Il a été conçu à des fins de recherche et de démonstration en data science appliquée aux ressources humaines, et constitue aujourd'hui l'un des benchmarks les plus utilisés dans la littérature sur la prédiction de l'attrition des employés. Bien que synthétique, il ne provient pas d'une organisation réelle, il reflète des dynamiques plausibles et couvre une diversité suffisante de variables RH pour permettre une analyse rigoureuse.

2.2. Prétraitement des données

Le prétraitement constitue une étape cruciale pour garantir la qualité des données avant la modélisation. Il inclut le nettoyage, la transformation (normalisation, standardisation) ainsi qu'une analyse exploratoire approfondie. Ces opérations ont été appliquées au data set afin de

corriger les biais, homogénéiser les formats et préparer un jeu de données cohérent, apte à alimenter les algorithmes d'apprentissage automatique.

2.2.1. Vérification initiale

Le jeu de données comprend **1 470 observations** (une par employé) et **35 variables** couvrant des dimensions démographiques, professionnelles et comportementales. La variable cible est **Attrition**, une variable binaire indiquant si l'employeur a quitté l'entreprise (Yes) ou non (No). Les variables se répartissent en quatre grandes catégories : quantitatives continues (salaire, ancienneté, âge), ordinales (niveaux de satisfaction, niveau d'éducation), nominales (département, rôle, statut marital) et constantes (sans variance utile).

Les variables quantitatives constituent la proportion la plus importante, avec 31 % de l'ensemble des variables. Les variables nominales représentent 23 %, tandis que les variables ordinales comptent pour 8 %. Par ailleurs, 23 % des variables ont été identifiées comme constantes et supprimées lors de la phase de prétraitement, et 8 % correspondent à une variable d'identification également retirée de l'analyse. La variable cible Attrition représente quant à elle 8 % de l'ensemble.




Figure 5: répartition des 35 variables du dataset IBM HR par type

La distribution de la variable cible Attrition au sein du jeu de données met en évidence un déséquilibre important entre les classes. Sur l'ensemble des observations, 1 233 employés (soit 83,9 %) appartiennent à la classe Non-attrition (employés restés dans l'entreprise), tandis que seulement 237 employés (soit 16,1 %) appartiennent à la classe Attrition (employés ayant quitté

l'entreprise). Cette répartition montre une forte dominance de la classe majoritaire, ce qui traduit un déséquilibre significatif des classes. Un tel déséquilibre peut biaiser les modèles de classification en favorisant la prédiction de la classe majoritaire au détriment de la classe minoritaire. Il est donc essentiel d'en tenir compte lors de l'entraînement et de l'évaluation des modèles, en privilégiant des métriques adaptées telles que le Recall, le F1-score ou l'AUC, et en envisageant éventuellement des techniques de rééquilibrage des données.




Figure 6: Distribution de la variable cible Attrition

2.2.2. Exploration et qualité des données

La première étape a consisté en une exploration systématique du dataset afin d'évaluer sa qualité et d'identifier les transformations nécessaires. L'analyse révèle aucune valeur manquante dans l'ensemble du jeu de données, ce qui simplifie le pipeline de prétraitement. L'examen des statistiques descriptives a néanmoins mis en évidence plusieurs points d'attention : une asymétrie positive (positive skewness) sur certaines variables comme **TotalWorkingYears** et **YearsSinceLastPromotion**, ainsi que la présence de valeurs aberrantes détectées par la méthode IQR sur les variables quantitatives.




Figure 7: Une asymétrie positive sur la variable TotalWorkingYears

2.2.3. Nettoyage et transformation

Trois variables présentent une variance nulle **EmployeeCount**, **Over18** et **StandardHours** dont la valeur est identique pour tous les employés. Ces variables ne peuvent contribuer à aucune discrimination prédictive et ont été supprimées. De même, **EmployeeNumber**, simple identifiant technique sans signification métier, a été éliminé pour éviter tout surajustement parasite.

Par ailleurs, 22 variables métier présentant un risque élevé de biais ou de redondance ont été écartées du périmètre de modélisation, notamment les variables salariales détaillées (**DailyRate**, **HourlyRate**, **MonthlyRate**), les scores de satisfaction multiples et les variables d'ancienneté corrélées entre elles. Cette décision vise à concentrer le modèle sur les signaux les plus robustes et à réduire le risque d'apprentissage de discriminations indirectes.

2.2.4. Détection des valeurs aberrantes

Les boxplots avant traitement des valeurs aberrantes révèlent la présence de valeurs extrêmes dans plusieurs variables continues. Pour l'âge, la distribution apparaît relativement normale avec peu de valeurs aberrantes, s'étendant approximativement de 18 à 60 ans avec une concentration autour de 30-40 ans.




Figure 8: Boxplot du variable 'Age'

Le nombre total d'années de travail présente des valeurs aberrantes significatifs, avec plusieurs points au-delà de 30 ans d'expérience, alors que la masse principale de la distribution se situe entre 0 et 20 ans.




Figure 9: Boxplot du variable *TotalWorkingYears*

La détection de ces valeurs aberrantes est cruciale pour décider si elles doivent être traitées, transformées ou conservées selon leur validité contextuelle et leur impact potentiel sur les analyses ultérieures.

2.2.5. Encodage des variables catégorielles

Les variables nominales **BusinessTravel**, **Gender** et **MaritalStatus**, ont été encodées via un **LabelEncoder**, transformant les modalités textuelles en valeurs numériques entières. Ce choix est adapté au contexte de classification binaire et compatible avec les algorithmes d'ensemble retenus. La variable cible **Attrition** a fait l'objet d'un mapping direct : No $\rightarrow$ 0, Yes $\rightarrow$ 1. Les correspondances d'encodage ont été sauvegardées pour garantir la traçabilité et permettre une interprétation correcte des résultats.

2.3. Analyse exploratoire des variables

2.3.1. Distribution globale des variables catégorielles




Figure 10: Pie chart du variable *Genre*

Les diagrammes circulaires fournissent une vue d'ensemble de la composition démographique et des caractéristiques de l'organisation. La distribution du genre révèle un déséquilibre notable avec 60% d'hommes et 40% de femmes, indiquant une représentation

masculine supérieure dans l'organisation. Ce déséquilibre pourrait refléter des patterns de l'industrie ou des biais historiques de recrutement, et constitue une considération importante pour les analyses de fairness algorithmique dans les modèles prédictifs d'attrition.

Pour les voyages d'affaires, la répartition montre une nette prédominance des employés voyageant rarement (71,0%), ce qui pourrait refléter la nature des rôles dans l'organisation où la majorité des postes sont basés localement. Les voyageurs fréquents (18,8%) et non-voyageurs (10,2%) constituent des minorités significatives.




Figure 12: Pie chart du variable BusinessTravel

Le statut marital montre une distribution relativement équilibrée avec une légère prédominance des employés mariés (45,8%). Les célibataires représentent une proportion substantielle (32,0%), tandis que les divorcés constituent un segment notable (22,2%). Cette diversité de statuts maritaux reflète une population d'employés à différentes étapes de leur vie personnelle, facteur potentiellement corrélé avec la stabilité professionnelle et les besoins en flexibilité du travail.




Figure 11: Pie chart du variable MaritalStatus

Ces distributions démographiques constituent des caractéristiques protégées importantes à considérer lors du développement de modèles de prédiction d'attrition éthiques et non biaisés.

2.3.2. Analyse des Variables Quantitatives selon le Statut d'Attrition

Les boxplots comparant les variables continues selon le statut d'attrition révèlent plusieurs tendances significatives. Pour l'âge, les employés qui quittent l'organisation tendent à être légèrement plus jeunes (médiane autour de 33-35 ans) comparés à ceux qui restent (médiane autour de 37 ans). Cette distribution suggère que les employés en début ou milieu de carrière présentent un risque d'attrition plus élevé, possiblement en raison d'une plus grande mobilité professionnelle ou d'aspirations de progression de carrière.




Figure 14: Age selon le Statut d'Attrition

La distance domicile-travail montre une légère tendance où les employés qui quittent l'organisation ont généralement une distance médiane plus élevée (environ 8-9 km) comparée à ceux qui restent (environ 7 km). Bien que la différence ne soit pas drastique, cela indique que la proximité du lieu de travail pourrait jouer un rôle dans la décision de rester dans l'organisation, particulièrement lorsque combinée avec d'autres facteurs.




Figure 13 DistanceFromHome selon le Statut d'Attrition

Le nombre total d'années de travail révèle une distinction marquée, les employés qui partent ont significativement moins d'expérience professionnelle totale (médiane autour de 7-8 ans)

comparés à ceux qui restent (médiane autour de 11-12 ans). Cette différence substantielle suggère que l'expérience professionnelle et potentiellement l'âge sont des indicateurs importants de stabilité.




Figure 15: TotalWorkingYears selon le Statut d'Attrition

2.3.3. Analyse des Variables Catégorielles selon le Statut d'Attrition

L'analyse des variables catégorielles révèle des patterns d'attrition distincts selon différents segments d'employés. La distribution du genre montre une main-d'œuvre à prédominance masculine (60,0% hommes, 40,0% femmes), avec des patterns d'attrition similaires pour les deux genres lorsqu'examinés proportionnellement. La comparaison basée sur les effectifs indique que bien que davantage d'hommes quittent l'organisation en chiffres absolus, cela reflète principalement la distribution globale du genre plutôt qu'un risque d'attrition spécifique au genre.




Figure 16: Distribution du genre selon le Statut d'Attrition

La fréquence des voyages d'affaires démontre une relation claire avec l'attrition : les employés qui voyagent rarement constituent le groupe le plus important du dataset (71,0%), suivis par ceux qui voyagent fréquemment (18,8%) et ceux qui ne voyagent pas (10,2%). De

manière notable, le taux d'attrition apparaît plus élevé parmi les employés qui voyagent fréquemment, suggérant que les exigences liées aux déplacements professionnels pourraient contribuer au turnover.




Figure 17: Fréquence des voyages d'affaires selon le Statut d'Attrition

Le statut marital révèle des insights intéressants, les employés mariés forment le segment le plus important (45,8%), suivis par les célibataires (32,0%) et les divorcés (22,2%). L'analyse de l'attrition montre que les employés célibataires présentent des taux de turnover plus élevés relativement à leur population, tandis que les employés mariés démontrent une meilleure rétention. Ce pattern suggère que le statut marital pourrait constituer un facteur de stabilité influençant les décisions de rétention des employés.




Figure 18: Le statut marital selon le Statut d'Attrition

2.3.4. Analyse Multivariée des Variables Quantitatives

Le pairplot offre une vue d'ensemble des relations entre variables continues, avec l'attrition distinguée par couleur. Les distributions diagonales révèlent : une distribution bimodale de l'âge, une asymétrie marquée de la distance domicile-travail vers les faibles valeurs, et une distribution discrète du nombre de formations. Les nuages de points montrent une corrélation

positive modérée entre l'âge et les années d'expérience, avec une dispersion reflétant des trajectoires de carrière variables ; les employés en attrition se concentrent dans les zones de jeune âge et faible expérience. La distance domicile-travail ne révèle pas de pattern clair, avec seulement une légère concentration de partants aux distances moyennes, tandis que le nombre de formations crée des bandes verticales sans séparation nette entre groupes. Au global, l'âge et le nombre total d'années de travail s'avèrent les variables continues les plus discriminantes pour l'attrition, tandis que la distance et les formations présentent des effets plus subtils, nécessitant potentiellement des interactions avec d'autres variables.




Figure 19: Analyse Multivariée des variables continues clés avec la distinction attrition

Le pipeline de prétraitement appliqué au dataset IBM HR Analytics a permis de réduire 35 variables initiales à 9 variables finales (8 prédicteurs + 1 variable cible), assurant la conservation des informations essentielles tout en limitant redondance et sources de biais. L'analyse exploratoire a par ailleurs mis en évidence des tendances et déséquilibres nécessitant un traitement spécifique, conduisant à une étape de feature engineering visant à optimiser la représentation des variables, améliorer la performance prédictive et étudier les biais potentiels avant la phase de modélisation.

3. Ingénierie et sélection des caractéristiques

Après prétraitement, le jeu de données réduit comprend 8 variables prédictives. Afin de confirmer la pertinence de chacune et d'identifier les contributions relatives, quatre méthodes de sélection de features ont été appliquées en parallèle : la **Random Forest Feature Importance**, l'**Information Mutuelle**, la **régression LASSO** et l'**Élimination Récursive de Features (RFE)**. Cette approche multi-méthodes permet d'obtenir une vision consensuelle de l'importance des variables, indépendante des hypothèses d'un modèle particulier.




Figure 20: Comparaison des méthodes de sélection de features

La figure présente une comparaison des scores d'importance normalisés (compris entre 0 et 1) attribués à chaque variable par quatre méthodes distinctes de sélection de caractéristiques. Cette visualisation permet d'observer le degré de convergence entre les approches utilisées. On constate notamment une cohérence marquée concernant les variables **TotalWorkingYears** et **Age**, dont les scores élevés et relativement stables à travers les différentes méthodes renforcent la confiance dans leur pertinence prédictive. La variable **MaritalStatus** obtient des scores modérés mais relativement stables, suggérant l'existence d'une corrélation avec les comportements d'attrition, ce que l'analyse exploratoire des données tend à confirmer.

À l'inverse, certaines variables, telles que **Gender**, obtiennent des scores inférieurs à 0,5 de manière systématique. Bien que leur contribution prédictive soit limitée, ces variables ont été conservées non pas pour améliorer la performance du modèle, mais pour permettre l'analyse et l'audit de l'équité, en évaluant d'éventuels biais dans les prédictions.

4. Analyse des biais

4.1. Le biais

Le biais algorithmique, également appelé biais de machine learning, désigne l'apparition de résultats discriminatoires causés par des préjugés humains introduits dans les données d'entraînement ou dans la conception même des algorithmes, pouvant engendrer des conséquences néfastes pour les individus et réduire la précision et la légitimité des systèmes d'IA. Dans le contexte de ce projet, où le modèle vise à évaluer les profils d'employés susceptibles de quitter l'organisation, de tels biais peuvent conduire à des décisions injustes envers certains groupes protégés, alimentant la méfiance et freinant une participation équitable à la vie économique. Notre objectif est donc de garantir la justice et l'équité algorithmique en détectant et en mesurant les biais présents dans le modèle avant d'appliquer les techniques de mitigation appropriées.

4.2. Identification des biais

Au niveau de cette partie de la détection des biais nous avons essayé de faire l'identification avant, durant et après l'entraînement.

❖ Les biais dans les données :

L'identification et l'atténuation des biais dans les données sont essentielles pour garantir que les systèmes d'intelligence artificielle (IA) et d'apprentissage automatique (ML) soient justes, précis et fiables. Pour ce faire nous avons utilisé le AIF360.

- **AIF360 :**

C'est une boîte à outils (framework) dépulper par IBM, qui contient les trois grandes catégories de techniques de l'quitté algorithmique d'un modèle d'Intelligence Artificielle ; avant, pendant et après l'entraînement, en offrant des métriques de l'équité pour identifier et mitiger les biais.

AIF360 structure les données en distinguant les groupes protégés et privilégiés, calcule des métriques d'équité basées sur des comparaisons statistiques entre groupes, puis propose des

algorithmes de mitigation agissant avant, pendant ou après l'apprentissage afin de réduire les disparités mesurées.

❖ Identification des biais avec AIF360 :

Généralement les caractéristiques d'un jeu de données se divisent en deux catégories principales ; la variable protégée qui est une caractéristique démographique ou sociale dont l'utilisation directe ou indirecte dans un modèle de Machine Learning peut conduire à une discrimination injuste entre groupes d'individus. Et la variable proxy qui est une variable apparemment neutre mais statistiquement corrélée à une variable protégée, permettant au modèle d'inférer indirectement l'attribut sensible et de reproduire un biais.

Dans notre jeu de données les variables protégées sont « Age » et « Gender », et les autres caractéristiques représente une variable proxy (ex : MaritalStatus).

Les résultats de l'identification des biais est représenté dans la table suivante :

Tableau 2: Résultat de l'identification de biais dans les données

Variables	Disparate Impact (DI)	Statistical Parity Difference (SPD)	Interprétation des résultats
Age (≥ 40 / < 40)	1.738	0.08067	DI et SPD indique l'existence d'un biais important
Age (Identification des biais pour distinguer les individus âgés entre 30 et 40 ans des autres)	1.30	0.042	DI indique l'existence d'un biais important SPD indique l'existence d'un biais négligeable
Gender	0.87	-0.0221	DI et SPD Indique d'un biais négligeable
MaritalStatus (Identification des biais	1.538	0.067	DI et SPD indique l'existence d'un biais important

entre les employés marié et les autres catégories)			
MritalStatus (Identification des biais entre les employés marié et célibataires)	2.045	0.130	DI et SPD indique l'existence d'un biais important

5. Évaluation des performances et analyse de l'équité des modèles :

Au niveau de cette étape dans notre projet nous avons expérimenté plusieurs modèles de Machine Learning au niveau de l'identification des biais et l'évaluation de la performance des modèles.

5.1. Évaluation des performances des modèles :

Le test de plusieurs modèles nous a permis de choisir le meilleur modèle, le tableau suivant représente l'évaluation de performance de chacun d'eux :

Tableau 3: Evaluation de la performance des modèles

Modèle	Accuracy	Precision (0)	Recall (0)	F1-Score (0)	Precision (1)	Recall (1)	F1-Score (1)
Logistique regression	0.660	0.879	0.689	0.773	0.238	0.507	0.324
Random forest	0.762	0.869	0.843	0.856	0.293	0.338	0.314
SVM	0.658	0.882	0.684	0.770	0.240	0.521	0.329
Gaussien Naive Bayes	0.624	0.886	0.632	0.738	0.232	0.577	0.331
KNN	0.660	0.885	0.684	0.771	0.245	0.535	0.336
Gaussien Boosting	0.705	0.861	0.773	0.815	0.229	0.352	0.278
XGBoost	0.744	0.862	0.827	0.844	0.256	0.310	0.280
MLP	0.728	0.868	0.797	0.831	0.257	0.366	0.302

Le diagramme à bar suivant représente la performance des modèles en se basant sur l'accuracy




Figure 21: Représentation graphique de l'accuracy

Ces deux diagrammes à bar représentent les métriques d'évaluation (Précision, Recall et F1 score) pour chaque classe ; la classe qui indique à ne pas embaucher et la classe qui indique à embaucher le profile.




Figure 22: Représentation graphique des métriques de performance

5.2. Analyse de l'équité des modèles :

Nous avons utilisé la bibliothèque AIF360 pour mesurer le biais dans les modèles, les résultats sont représentés dans les tableaux suivants :

❖ Régression logistique :

Tableau 4: : Identification des biais pour le modèle de la régression logistique

Variable	Groupe privilégié vs Groupe comparé	Disparate Impact (DI)	Statistical Parity Difference (SPD)	Interprétation
Genre	Homme (priv.) vs Femme	1.506	0.145	Biais modéré sur les deux métriques
Âge	≥ 40 (priv.) vs < 40	4.769	0.372	Biais significatif et action corrective recommandée
Statut marital	Marié (priv.) vs autres	1.247	0.074	DI acceptable, biais SPD modéré
Déplacements professionnels	Fréquent (priv.) vs rare/jamais	0.732	-0.117	Biais modéré sur les deux métriques
Distance domicile- travail	< 16 km (priv.) vs ≥ 16 km	1.633	0.192	Biais modéré sur les deux métriques
Niveau d'éducation	Élevé (priv.) vs faible	2.819	0.277	Biais significatif et action corrective recommandée
Formations reçues	≥ 4 (priv.) vs < 4	3.534	0.303	Biais significatif et action corrective recommandée
Années d'expérience	≥ 11 ans (priv.) vs < 11 ans	9.980	0.455	Biais significatif et action corrective recommandée

❖ Random Forest :

Tableau 5: Identification des biais pour le modèle Random Forest

Variable	Groupe privilégié vs Groupe comparé	Disparate Impact (DI)	Statistical Parity Difference (SPD)	Interprétation
Genre	Homme (priv.) vs Femme	1.864	0.121	Biais modéré sur les deux métriques
Âge	≥ 40 (priv.) vs < 40	3.068	0.163	Biais significatif action corrective recommandée
Statut marital	Marié (priv.) vs autres	0.762	-0.051	Biais modéré sur les deux métriques
Déplacements professionnels	Fréquent (priv.) vs rare/jamais	0.321	-0.273	Biais significatif et action corrective recommandée
Distance domicile- travail	< 16 km (priv.) vs ≥ 16 km	1.241	0.043	Équitable et aucun biais détecté

Niveau d'éducation	Élevé (priv.) vs faible	5.769	0.207	Biais significatif et action corrective recommandée
Formations reçues	≥ 4 (priv.) vs < 4	1.381	0.055	Biais modéré sur les deux métriques
Années d'expérience	≥ 11 ans (priv.) vs < 11 ans	5.164	0.211	Biais significatif et action corrective recommandée

❖ SVM :

Tableau 6: Identification des biais pour le modèle SVM

Variable	Groupe privilégié vs Groupe comparé	Disparate Impact (DI)	Statistical Parity Difference (SPD)	Interprétation
Genre	Homme (priv.) vs Femme	1.528	0.153	Biais modéré sur les deux métriques
Âge	≥ 40 (priv.) vs < 40	4.536	0.372	Biais significatif et action corrective recommandée
Statut marital	Marié (priv.) vs autres	1.187	0.059	DI acceptable, biais SPD modéré
Déplacements professionnels	Fréquent (priv.) vs rare/jamais	0.751	-0.108	Biais modéré sur les deux métriques
Distance domicile-travail	< 16 km (priv.) vs ≥ 16 km	1.689	0.211	Biais modéré sur les deux métriques
Niveau d'éducation	Élevé (priv.) vs faible	2.884	0.287	Biais significatif et action corrective recommandée
Formations reçues	≥ 4 (priv.) vs < 4	3.611	0.312	Biais significatif et action corrective recommandée
Années d'expérience	≥ 11 ans (priv.) vs < 11 ans	8.995	0.455	Biais significatif et action corrective recommandée

❖ Gaussian Naive Bayes :

Tableau 7: Identification des biais pour le modèle Gaussian Naive Bayes

Variable	Groupe privilégié vs Groupe comparé	Disparate Impact (DI)	Statistical Parity Difference (SPD)	Interprétation
Genre	Homme (priv.) vs Femme	1.421	0.146	Biais modéré sur les deux métriques
Âge	≥ 40 (priv.) vs < 40	8.783	0.512	Biais significatif — action corrective recommandée

Variable	Groupe privilégié vs Groupe comparé	Disparate Impact (DI)	Statistical Parity Difference (SPD)	Interprétation
Statut marital	Marié (priv.) vs autres	1.140	0.052	DI acceptable, biais SPD modéré
Déplacements professionnels	Fréquent (priv.) vs rare/jamais	0.773	-0.111	Biais modéré sur les deux métriques
Distance domicile-travail	<16 km (priv.) vs ≥16 km	1.391	0.145	Biais modéré sur les deux métriques
Niveau d'éducation	Élevé (priv.) vs faible	3.050	0.342	Biais significatif — action corrective recommandée
Formations reçues	≥4 (priv.) vs <4	3.190	0.337	Biais significatif — action corrective recommandée
Années d'expérience	≥11 ans (priv.) vs <11 ans	13.559	0.556	Biais significatif — action corrective recommandée

❖ KNN :

Tableau 8: Identification des biais pour le modèle KNN

Variable	Groupe privilégié vs Groupe comparé	DI	SPD	Interprétation
Genre	Homme vs Femme	1.325	0.102	Biais modéré sur les deux métriques
Âge	≥40 vs <40	2.022	0.215	Biais significatif et action corrective recommandée
Statut marital	Marié vs autres	0.971	-0.010	Équitable et aucun biais détecté
Déplacements pro	Fréquent vs rare/jamais	0.441	-0.352	Biais significatif et action corrective recommandée
Distance domicile-travail	<16 km vs ≥16 km	1.338	0.111	Biais modéré sur les deux métriques
Niveau d'éducation	Élevé vs faible	1.979	0.206	Biais modéré sur les deux métriques
Formations reçues	≥4 vs <4	1.792	0.176	Biais modéré sur les deux métriques
Années d'expérience	≥11 vs <11	1.987	0.212	Biais modéré sur les deux métriques

❖ Gradient Boosting :

Tableau 9: Identification des biais pour le modèle Gradient Boosting

Variable	Groupe privilégié vs Groupe comparé	DI	SPD	Interprétation
Genre	Homme vs Femme	1.523	0.108	Biais modéré sur les deux métriques

Variable	Groupe privilégié vs Groupe comparé	DI	SPD	Interprétation
Âge	≥40 vs <40	2.659	0.196	Biais significatif et action corrective recommandée
Statut marital	Marié vs autres	1.228	0.050	DI acceptable, biais SPD modéré
Déplacements pro	Fréquent vs rare/jamais	0.259	- 0.443	Biais significatif et action corrective recommandée
Distance domicile-travail	<16 km vs ≥16 km	0.711	- 0.076	Biais modéré sur les deux métriques
Niveau d'éducation	Élevé vs faible	3.091	0.212	Biais significatif — action corrective recommandée
Formations reçues	≥4 vs <4	1.513	0.092	Biais modéré sur les deux métriques
Années d'expérience	≥11 vs <11	3.499	0.237	Biais significatif et action corrective recommandée

❖ XGBoost :

Tableau 10: Identification des biais pour le modèle XGBoost

Variable	Groupe privilégié vs Groupe comparé	DI	SPD	Interprétation
Genre	Homme vs Femme	1.609	0.096	Biais modéré sur les deux métriques
Âge	≥40 vs <40	2.705	0.157	Biais significatif et action corrective recommandée
Statut marital	Marié vs autres	0.800	- 0.044	Équitable et aucun biais détecté
Déplacements pro	Fréquent vs rare/jamais	0.384	- 0.234	Biais significatif et action corrective recommandée
Distance domicile-travail	<16 km vs ≥16 km	0.813	- 0.038	Équitable et aucun biais détecté
Niveau d'éducation	Élevé vs faible	3.461	0.178	Biais significatif et action corrective recommandée
Formations reçues	≥4 vs <4	1.192	0.033	Équitable et aucun biais détecté
Années d'expérience	≥11 vs <11	2.443	0.146	Biais significatif et action corrective recommandée

6. Phase d'optimisation du cycle Recherche et Développement (R&D) – Amélioration de la précision et correction de biais

6.1. Traitement du déséquilibre de classes

6.1.1. Contexte et motivation

Dans le cadre de la prédiction de l'attrition du personnel, la variable cible Attrition présente un déséquilibre marqué : sur 1 470 observations, seuls 237 cas correspondent à un départ effectif

(classe 1), contre 1 233 cas de stabilité (classe 0). Ce déséquilibre, caractéristique des problèmes RH où les événements rares sont souvent les plus importants à détecter, peut induire des modèles biaisés en faveur de la classe majoritaire. Les classifieurs standards tendent alors à prédire majoritairement la classe 0, sacrifiant la capacité à identifier correctement les cas d'attrition, pourtant critiques pour la prise de décision.

Pour remédier à cette situation, différentes stratégies de rééquilibrage ont été explorées, allant de l'ajustement des poids des classes lors de l'apprentissage à la génération synthétique d'exemples de la classe minoritaire. L'objectif est d'améliorer la sensibilité (rappel) du modèle vis-à-vis de la classe d'intérêt sans dégrader excessivement la précision globale.

6.1.2. Techniques mises en œuvre

Quatre approches complémentaires ont été évaluées :

❖ Pondération des classes (class_weight) :

Dans un premier temps, nous avons utilisé le paramètre `class_weight='balanced_subsample'` pour Random Forest) afin d'ajuster automatiquement les poids des classes de manière inversement proportionnelle à leurs fréquences. Cette approche pénalise davantage les erreurs sur la classe minoritaire. Les résultats obtenus pour chaque modèle sont présentés dans le tableau récapitulatif. En particulier, pour la **régression logistique**, on observe un rappel de 0,64 et une précision de 0,23 (F1-score = 0,34), tandis que pour **SVM** le rappel atteint 0,55 avec une précision de 0,26 (F1-score = 0,36). En revanche, pour **Random Forest**, le rappel n'est que de 0,11 malgré une bonne précision (0,50), ce qui montre que la simple pondération est insuffisante pour les modèles non linéaires dans ce contexte.

=====				
ANALYSE DÉTAILLÉE : RANDOM FOREST				
=====				
	precision	recall	f1-score	support
0	0.85	0.98	0.91	247
1	0.50	0.11	0.18	47
accuracy			0.84	294
macro avg	0.68	0.54	0.54	294
weighted avg	0.80	0.84	0.79	294

Figure 23 : RANDOM FOREST AVEC POIDS

On observe que la classe minoritaire est détectée dans **11 %** des cas (rappel = 0,11), avec une précision de **50 %**. Cela montre que la simple pondération permet déjà d'améliorer la sensibilité, mais reste insuffisante pour une détection satisfaisante.

❖ SMOTE (Technique de suréchantillonnage synthétique des minorités) :

SMOTE génère de nouveaux exemples synthétiques pour la classe minoritaire en interpolant entre les échantillons existants. Après application sur l'ensemble d'entraînement, la distribution est devenue équilibrée (986 instances pour chaque classe). Les performances ont été évaluées sur plusieurs classifieurs. Pour **Random Forest**, le rappel atteint 0,28 avec une précision de 0,32 (F1-score = 0,30). **k-NN** obtient un rappel remarquable de 0,49 (précision 0,23, F1-score = 0,32). La **régression logistique** et **SVM** affichent des rappels respectifs de 0,51 et 0,36, avec des F1-scores de 0,32 et 0,29. Globalement, SMOTE améliore nettement la détection de la classe minoritaire par rapport à la simple pondération pour les modèles ensemblistes et k-NN.

=====				
ANALYSE DÉTAILLÉE : RANDOM FOREST				
=====				
	precision	recall	f1-score	support
0	0.87	0.89	0.88	247
1	0.32	0.28	0.30	47
accuracy			0.79	294
macro avg	0.59	0.58	0.59	294
weighted avg	0.78	0.79	0.78	294

Figure 24:Random forest avec SMOTE

Le recall de la classe 1 atteint 28 %, mais la précision reste faible (32 %), indiquant un taux élevé de faux positifs.

❖ SMOTETomek (combinaison de SMOTE et Tomek Links) :

Cette technique hybride applique d'abord SMOTE pour sur-échantillonner la classe minoritaire, puis élimine les paires d'exemples proches de classes différentes (Tomek Links) afin de nettoyer les frontières de décision. Les résultats sont très proches de ceux obtenus avec

SMOTE seul. Pour **SVM**, le rappel est de 0,36 (précision 0,24, F1-score = 0,29) ; pour la **régression logistique**, le rappel atteint 0,51 (précision 0,23, F1-score = 0,32). **Random Forest** donne un rappel de 0,23 (F1-score = 0,25). L'apport des Tomek Links ne semble pas significatif dans notre cas.

```
=====
ANALYSE DÉTAILLÉE : LOGISTIC REGRESSION
=====
```

	precision	recall	f1-score	support
0	0.88	0.68	0.77	247
1	0.23	0.51	0.32	47
accuracy			0.65	294
macro avg	0.56	0.60	0.54	294
weighted avg	0.78	0.65	0.70	294

Figure 25: SMOTETomek avec SVR et Régression logistique

❖ SMOTEENN (SMOTE + Voisins les plus proches modifiés) :

Après sur-échantillonnage par SMOTE, on applique l'algorithme ENN qui supprime les exemples dont la classe diffère de celle de la majorité de ses k plus proches voisins. Cette approche vise à éliminer les échantillons bruités. Les performances sont globalement inférieures à celles des autres méthodes. Le modèle **SVM** atteint un rappel de 0,27 (précision 0,19, F1-score = 0,22), tandis que la **régression logistique** obtient un rappel de 0,33 (précision 0,18, F1-score = 0,23). Pour **Random Forest**, le rappel chute à 0,11 (F1-score = 0,15). SMOTEENN semble trop agressif et dégrade la détection.

```
=====
ANALYSE DÉTAILLÉE : SVM (SUPPORT VECTOR)
=====
```

	precision	recall	f1-score	support
0	0.86	0.80	0.83	249
1	0.19	0.27	0.22	45
accuracy			0.72	294
macro avg	0.53	0.53	0.53	294
weighted avg	0.76	0.72	0.74	294

Figure 26 : SMOTEENN avec SVR et Régression logistique

6.1.3. Synthèse comparative des performances

Le tableau ci-dessous rassemble les métriques obtenues pour la classe minoritaire (classe 1) avec chaque technique et chaque modèle. Les valeurs en gras indiquent les meilleurs résultats pour chaque métrique.

- **Modèle** : Algorithme de classification utilisé (régression logistique, SVM, forêt aléatoire, etc.).
- **Métrique** : Indicateur de performance évalué (précision, rappel ou F1-score) pour la classe minoritaire.
- **Class weight** : Résultats obtenus avec simple pondération des classes lors de l'apprentissage, sans rééchantillonnage.
- **SMOTE** : Performances après sur-échantillonnage synthétique de la classe minoritaire par interpolation.
- **SMOTETomek** : Combinaison de SMOTE et suppression des Tomek links pour nettoyer les frontières.
- **SMOTEENN** : Association de SMOTE et Edited Nearest Neighbors pour éliminer les échantillons bruités.

Tableau 11: Comparaison des performances sur la classe minoritaire (Attrition = 1)

Modèle	Métrique	Class weight	SMOTE	SMOTETomek	SMOTEENN
Régression logistique	Precision	0,23	0,24	0,23	0,18
	Recall	0,64	0,51	0,51	0,33
	F1-score	0,34	0,32	0,32	0,23
SVM	Precision	0,26	0,24	0,24	0,19
	Recall	0,55	0,36	0,36	0,27
	F1-score	0,36	0,29	0,29	0,22

Modèle	Métrique	Class weight	SMOTE	SMOTETomek	SMOTEENN
Random Forest	Precision	0,50	0,32	0,27	0,23
	Recall	0,11	0,28	0,23	0,11
	F1-score	0,18	0,30	0,25	0,15
Gradient Boosting	Precision	0,31	0,21	0,24	0,21
	Recall	0,09	0,28	0,30	0,18
	F1-score	0,13	0,24	0,26	0,19
k-NN	Precision	0,36	0,23	0,24	0,16
	Recall	0,11	0,49	0,49	0,20
	F1-score	0,16	0,32	0,32	0,18

La pondération des classes (`class_weight`) s'avère très efficace pour certains modèles, en particulier la régression logistique et le SVM, qui atteignent des rappels élevés (0,64 et 0,55) avec des f1-scores respectifs de 0,34 et 0,36. Pour la régression logistique, c'est même la meilleure performance en termes de f1-score parmi toutes les méthodes. En revanche, pour les modèles basés sur les arbres (Random Forest, Gradient Boosting) et k-NN, le rappel reste très faible ($\leq 0,11$), ce qui indique que ces algorithmes réagissent moins bien à la simple pondération.

SMOTE améliore nettement le rappel pour Random Forest (0,28), Gradient Boosting (0,28) et k-NN (0,49), avec des f1-scores supérieurs à ceux obtenus par pondération pour ces modèles. Pour la régression logistique et SVM, SMOTE donne des résultats légèrement inférieurs à la pondération, mais reste honorable.

SMOTETomek produit des performances très similaires à SMOTE pour la plupart des modèles, avec une légère amélioration pour Gradient Boosting (rappel 0,30, f1 0,26) et une

légère baisse pour Random Forest. Globalement, l'ajout de Tomek Links n'apporte pas de gain significatif par rapport à SMOTE seul dans ce contexte.

SMOTEENN donne les résultats les plus faibles pour tous les modèles, avec une dégradation marquée du rappel et du f1-score. Cette technique, plus agressive dans le nettoyage des données, semble supprimer trop d'information utile, pénalisant ainsi la détection de la classe minoritaire.




Figure 27: Comparaison globale des métriques par modèle et technique

Ce graphique est composé de trois sous-figures (Précision, Rappel, F1-score). Pour chaque métrique, les cinq modèles sont représentés en abscisse, avec des barres groupées correspondant aux quatre techniques de rééquilibrage (Class weight, SMOTE, SMOTETomek, SMOTEENN). Les valeurs sont affichées directement sur les barres. Il permet d'identifier rapidement quelle technique offre le meilleur compromis pour chaque métrique et pour chaque modèle.

La **régression logistique avec simple pondération** offre le meilleur compromis ($f1 = 0,34$, $rappel = 0,64$) pour la classe minoritaire. Cependant, sa précision modeste ($0,23$) indique un taux élevé de faux positifs (102 sur 247), ce qui peut être acceptable si l'objectif est de ne pas manquer de départs potentiels, mais risqué si les ressources pour traiter les faux positifs sont limitées.

SVM avec pondération présente également un bon équilibre ($f1 = 0,36$, $rappel = 0,55$) avec une précision légèrement supérieure ($0,26$).

Pour les modèles ensemblistes (Random Forest, Gradient Boosting), **SMOTE** reste la meilleure option, bien que les performances globales soient inférieures à celles des modèles linéaires avec pondération.

k-NN avec SMOTE atteint un rappel remarquable de 0,49 et un f1 de 0,32, ce qui en fait un concurrent sérieux, mais sa précision faible (0,23) limite son intérêt pratique.

6.2. Optimisations avancées après rééquilibrage

Une fois le déséquilibre de classes traité par les techniques de rééchantillonnage (SMOTE, SMOTETomek, SMOTEENN) et la pondération, nous avons exploré diverses approches pour améliorer encore la détection de la classe minoritaire (attrition). Ces méthodes incluent l'ajustement du seuil de décision, l'optimisation des hyperparamètres, la combinaison de modèles, l'utilisation de classificateurs spécialisés pour les données déséquilibrées, et la construction d'ensembles personnalisés. Cette section décrit chaque technique et présente ses performances sur l'ensemble de test.

6.2.1. Ajustement du seuil de décision (régression logistique + SMOTE)

Après avoir équilibré les données d'entraînement par SMOTE, nous avons entraîné une régression logistique avec le paramètre `class_weight='balanced'` et un nombre maximal d'itérations fixé à 1000. Le seuil de décision par défaut de 0,5 a été relevé à 0,75 afin de ne retenir que les prédictions les plus certaines, dans le but de réduire les faux positifs. Sur l'ensemble de test, cette configuration a produit une précision de 0,25 pour la classe minoritaire, un rappel de 0,06 et un F1-score de 0,10. La matrice de confusion associée est $\begin{bmatrix} 238 & 9 \\ 44 & 3 \end{bmatrix}$, indiquant que seuls 3 vrais départs sur 47 ont été détectés, contre 9 faux positifs. Ce seuil strict pénalise fortement le rappel et s'avère inadapté à notre objectif.




Figure 28: Ajustement du seuil de décision

6.2.2. Optimisation des hyperparamètres de XGBoost (GridSearchCV)

Nous avons construit un pipeline incluant une normalisation par StandardScaler et un classifieur XGBoost, puis effectué une recherche par grille (GridSearchCV) avec validation croisée stratifiée en 5 folds, en optimisant le score `f1_macro`. L'espace de recherche comprenait les paramètres suivants : `n_estimators` (50, 100), `max_depth` (2, 4), `learning_rate` (0,01, 0,05, 0,1), `subsample` (0,5, 0,8), `colsample_bytree` (0,8, 1,0) et plusieurs valeurs de `scale_pos_weight` autour du ratio calculé ($\approx 5,19$). Les meilleurs paramètres obtenus sont `colsample_bytree`=1,0, `learning_rate`=0,01, `max_depth`=2, `n_estimators`=100, `scale_pos_weight`=4,15 et `subsample`=0,5. Sur l'ensemble de test, ce modèle atteint une précision de 0,262, un rappel de 0,234 et un F1-score de 0,247 pour la classe minoritaire, avec une matrice de confusion $\begin{bmatrix} 216 & 31 \\ 36 & 11 \end{bmatrix}$. Il détecte ainsi 11 départs sur 47, améliorant le rappel par rapport au seuillage.




Figure 29: Optimisation des hyperparamètres de XGBoost

6.2.3. Combinaison de modèles par vote pondéré (SMOTE + Voting)

Pour bénéficier de la complémentarité de plusieurs algorithmes, nous avons construit un VotingClassifier avec trois estimateurs : une régression logistique, une forêt aléatoire configurée avec `n_estimators`=200 et `min_samples_leaf`=2, et un XGBoost utilisant le paramètre `scale_pos_weight` ajusté au ratio. Le vote est de type soft (moyenne des probabilités) avec des poids respectifs de 1, 2 et 3 pour favoriser les modèles les plus performants. Un pipeline intègre une normalisation par StandardScaler et un sur-échantillonnage SMOTE avec une stratégie d'échantillonnage fixée à 0,5 avant le vote. Les résultats sur le test montrent une précision de 0,23, un rappel de 0,17 et un F1-score de 0,20 pour la classe minoritaire, avec la

matrice $[[220, 27], [39, 8]]$. Seulement 8 vrais positifs sont identifiés, et les performances sont inférieures à celles du XGBoost seul.




Figure 30: Combinaison de modèles par vote

6.2.4. ADASYN avec Random Forest optimisé (GridSearchCV)

ADASYN (Adaptive Synthetic Sampling) génère des échantillons synthétiques en se concentrant sur les zones difficiles. Nous l'avons intégré dans un pipeline avec normalisation et une forêt aléatoire, dont les hyperparamètres ont été optimisés par GridSearchCV (critère `f1_macro`). La grille de recherche incluait `n_estimators` (100, 200), `max_depth` (None, 15, 20), `min_samples_split` (2, 5), `min_samples_leaf` (1, 2) et `max_features` ('sqrt', 'log2'). Les meilleurs paramètres sont `max_depth=15`, `max_features='sqrt'`, `min_samples_leaf=1`, `min_samples_split=2` et `n_estimators=100`. Sur l'ensemble de test, ce modèle obtient une précision de 0,300, un rappel de 0,128 et un F1-score de 0,179 pour la classe minoritaire, avec la matrice $[[233, 14], [41, 6]]$. La précision est élevée, mais le rappel reste faible (seulement 6 départs détectés).




Figure 31: ADASYN avec Random Forest optimisé

6.2.5. Optimisation manuelle du paramètre `class_weight` pour *Random Forest*

Au-delà de l'option 'balanced', nous avons testé plusieurs valeurs manuelles pour le poids de la classe minoritaire sur une forêt aléatoire fixe (200 arbres, profondeur maximale 20, `min_samples_split=5`, `min_samples_leaf=2`). Les poids testés comprenaient le ratio exact (5,19), des ratios réduits ($0,7\times$, $0,8\times$) et augmentés ($1,2\times$, $1,5\times$, $2\times$), ainsi que des valeurs fixes comme 10 et 15. La meilleure configuration, retenue pour maximiser le F1-score, est {0: 1, 1: 10}. Elle donne une précision de 0,276, un rappel de 0,170 et un F1-score de 0,211 pour la classe minoritaire, améliorant légèrement le F1 par rapport à 'balanced'.




Figure 32: Optimisation manuelle du paramètre

6.2.6. Recherche aléatoire d'hyperparamètres pour *Random Forest* (*RandomizedSearchCV*)

Pour explorer un large espace de recherche, nous avons utilisé `RandomizedSearchCV` avec 50 itérations, en optimisant le F1-score de la classe minoritaire grâce à un `make_scorer` approprié. L'espace incluait `n_estimators` (100 à 500), `max_depth` (10 à 30 ou None), `min_samples_split` (2 à 15), `min_samples_leaf` (1 à 6), `max_features` ('sqrt', 'log2', 0,3, 0,5), `max_samples` (0,7 à 0,9 ou None), `criterion` ('gini', 'entropy') et `class_weight` ('balanced', 'balanced_subsample'). Les meilleurs paramètres obtenus sont `n_estimators=500`, `min_samples_split=10`, `min_samples_leaf=6`, `max_samples=0,9`, `max_features=0,3`, `max_depth=20`, `criterion='gini'` et `class_weight='balanced'`. Sur le test, ce modèle affiche une précision de 0,24, un rappel de 0,26 et un F1-score de 0,25, avec la matrice $\begin{bmatrix} 209 & 38 \\ 35 & 12 \end{bmatrix}$ et une ROC-AUC de 0,643. Il équilibre mieux précision et rappel que les précédents.




Figure 33: Recherche aléatoire d'hyperparamètres pour Random Forest

6.2.7. *Balanced Random Forest (imblearn)*

Le `BalancedRandomForestClassifier` de la bibliothèque `imblearn` sous-échantillonne aléatoirement chaque arbre pour équilibrer les classes. Nous avons optimisé ses hyperparamètres par `RandomizedSearchCV` (30 itérations) en maximisant le F1-score de la classe minoritaire. L'espace de recherche comprenait `n_estimators` (100, 200, 300), `max_depth` (15, 20, 25, 30), `min_samples_split` (2, 5, 10), `min_samples_leaf` (1, 2, 4), `max_features` ('sqrt', 'log2'), `sampling_strategy` ('auto', 'all', 'not minority') et `replacement` (True, False). Les meilleurs paramètres sont `sampling_strategy='auto'`, `replacement=False`, `n_estimators=100`, `min_samples_split=10`, `min_samples_leaf=1`, `max_features='sqrt'` et `max_depth=20`. Sur le test, ce modèle atteint une précision de 0,23, un rappel de 0,55 et un F1-score de 0,33, avec la matrice $\begin{bmatrix} 162 & 85 \\ 21 & 26 \end{bmatrix}$ et une ROC-AUC de 0,646. Il offre le meilleur rappel (55 %) et le meilleur F1-score parmi toutes les approches.




Figure 34: Balanced Random Forest

6.2.8. Ensemble personnalisé de Random Forests (bagging)

Nous avons construit un ensemble de trois forêts aléatoires aux caractéristiques différentes : la première avec `class_weight='balanced'`, 200 arbres et une profondeur maximale de 20 ; la seconde avec un poids manuel $\{0:1, 1:10,38\}$ (soit le ratio multiplié par 2), 200 arbres et une profondeur de 25 ; la troisième avec `class_weight='balanced_subsample'`, 300 arbres, une profondeur illimitée et `min_samples_split=2`. Les probabilités prédites par ces trois modèles sont moyennées, puis un seuil optimal est recherché pour maximiser le F1-score, aboutissant à un seuil de 0,14. Sur l'ensemble de test, cet ensemble donne une précision de 0,21, un rappel de 0,60 et un F1-score de 0,31, avec la matrice $\begin{bmatrix} 143 & 104 \\ 19 & 28 \end{bmatrix}$ et une ROC-AUC de 0,618. Le rappel atteint 60 % (28 départs détectés), mais au prix de 104 faux positifs.




Figure 35: Ensemble personnalisé de Random

Tableau comparatif des techniques d'optimisation

Le tableau ci-dessous synthétise les performances obtenues pour la classe minoritaire (attrition = 1) avec les différentes approches testées :

- **Technique** : Méthode d'optimisation ou modèle utilisé pour la prédiction de l'attrition.
- **Précision** : Proportion de prédictions positives correctes parmi toutes les prédictions positives pour la classe minoritaire.
- **Rappel** : Proportion de vrais positifs détectés parmi tous les cas réels d'attrition.
- **F1-score** : Moyenne harmonique de la précision et du rappel, mesurant la performance globale sur la classe minoritaire.

Tableau 12: Tableau comparatif des techniques d'optimisation

Technique	Précision	Rappel	F1-score
Seuil 0,75 (régression logistique + SMOTE)	0,25	0,06	0,10
XGBoost optimisé (GridSearchCV)	0,262	0,234	0,247
Voting Classifier (SMOTE + XGBoost)	0,23	0,17	0,20
ADASYN + Random Forest (GridSearchCV)	0,300	0,128	0,179
Optimisation manuelle class_weight RF (poids 1:10)	0,276	0,170	0,211
Random Forest optimisé (RandomizedSearchCV)	0,24	0,26	0,25
Balanced Random Forest (imblearn)	0,23	0,55	0,33
Ensemble de Random Forests (bagging, seuil 0,14)	0,21	0,60	0,31
Random Forest simple class_weight (modèle retenu)	0,50	0,11	0,18

Graphique compare les trois métriques (précision, rappel, F1-score) pour chaque technique :




Figure 36: graphique compare les trois métriques

6.2.9. Modèle retenu : Random Forest avec `class_weight='balanced'`

Malgré des performances inférieures en rappel et F1-score par rapport au Balanced Random Forest ou à l'ensemble bagging, nous avons sélectionné une forêt aléatoire simple avec le paramètre `class_weight='balanced'` comme modèle de base pour la suite du projet (phase de mitigation des biais). Ce choix est motivé par sa précision élevée (50 % sur la classe minoritaire), qui minimise les faux positifs (seulement 5), un atout dans un contexte RH où chaque alerte injustifiée peut entraîner des actions inutiles. Sa simplicité et sa rapidité d'exécution facilitent le déploiement et l'interprétation, et il servira de baseline robuste pour évaluer l'impact des techniques de fairness. Les résultats obtenus avec `RandomForestClassifier` (`class_weight = 'balanced'`, `random_state = 42`) sans rééchantillonnage sont les suivants : précision de 0,50, rappel de 0,11 et F1-score de 0,18, avec la matrice de confusion [[242, 5], [42, 5]]. Ce modèle détecte seulement 5 départs sur 47, mais avec une confiance élevée et très peu de faux positifs.




Figure 37:Modèle retenu

6.3. Correction des biais algorithmiques par Reconditionnement (Reweighting)

6.3.1. Identification des attributs sensibles biaisés

L'analyse des biais a mis en évidence des disparités dans les prédictions du modèle initial selon deux attributs sensibles : la situation familiale (`MaritalStatus`) et le genre (`Gender`). Pour `MaritalStatus`, les groupes privilégié (célibataires, codé 1) et défavorisé (mariés, codé 2) présentaient des taux de prédiction positive inégaux. Pour `Gender`, les hommes (codé 1) étaient favorisés par rapport aux femmes (codé 0). Afin de corriger ces biais, nous avons appliqué une technique de prétraitement appelée **Reconditionnement** (Reweighting), qui attribue des poids aux instances d'apprentissage de façon à rendre les distributions conditionnelles des classes indépendantes du groupe protégé.

6.3.2. Méthodologie de correction

La correction a été menée indépendamment pour chaque attribut sensible selon le protocole suivant. Dans un premier temps, les données ont été divisées en ensembles d'entraînement et de test selon une proportion 70/30, avec stratification sur la variable cible Attrition afin de préserver la distribution originale. Les caractéristiques numériques ont ensuite été normalisées à l'aide de StandardScaler. Pour formaliser les groupes protégés, nous avons utilisé la bibliothèque aif360 en créant un objet BinaryLabelDataset spécifiant l'attribut sensible, les groupes privilégié et défavorisé, ainsi que la classe favorable (l'attrition, codée 1). La méthode Reweighing a été appliquée sur l'ensemble d'entraînement pour calculer des poids d'instance qui rééquilibrent les contributions de chaque groupe. Un modèle RandomForestClassifier a ensuite été entraîné sur les données normalisées en intégrant ces poids via le paramètre `sample_weight`, tout en conservant l'option `class_weight='balanced_subsample'` pour renforcer la prise en compte du déséquilibre des classes. Les hyperparamètres de chaque forêt ont été préalablement optimisés par validation croisée pour garantir une performance prédictive satisfaisante. Enfin, les prédictions sur l'ensemble de test ont été évaluées à la fois en termes d'exactitude (accuracy) et de métriques d'équité : le *Disparate Impact* (rapport des taux de prédiction positive entre groupes défavorisé et privilégié, idéalement proche de 1) et la *Statistical Parity Difference* (différence des taux, idéalement proche de 0).

6.3.3. Correction du biais lié à la situation familiale (MaritalStatus)

Pour l'attribut MaritalStatus, le groupe privilégié a été défini comme les célibataires (valeur 1) et le groupe défavorisé comme les mariés (valeur 2). Les hyperparamètres retenus pour la forêt aléatoire après optimisation sont les suivants : 53 arbres (`n_estimators`), une profondeur maximale de 8 (`max_depth`), un nombre minimal d'échantillons pour diviser un nœud de 10 (`min_samples_split`) et un nombre minimal d'échantillons par feuille de 5 (`min_samples_leaf`). Après application du reweighing, le modèle a atteint une exactitude de 78,46 % sur l'ensemble de test. Les métriques d'équité montrent une quasi-parité parfaite : le Disparate Impact s'élève à 1,0292, très proche de l'unité, et la Statistical Parity Difference n'est que de 0,0045. Ces valeurs indiquent que les taux de prédiction positive sont pratiquement identiques entre les deux groupes, ce qui témoigne de l'efficacité de la correction pour cet attribut.

6.3.4. Correction du biais lié au genre (Gender)

Dans le cas du genre, les hommes (valeur 1) ont été considérés comme le groupe privilégié et les femmes (valeur 0) comme le groupe défavorisé. Les hyperparamètres du modèle ont été choisis de manière à éviter un surapprentissage tout en maintenant une bonne généralisation : 70 arbres, une profondeur maximale limitée à 2, un minimum de 5 échantillons pour diviser un nœud et un minimum de 15 échantillons par feuille. L'exactitude obtenue sur le test est de 71,43 %. Les indicateurs d'équité révèlent un Disparate Impact de 1,2017, ce qui signifie que les femmes ont un taux de prédiction positive environ 20 % supérieur à celui des hommes. La Statistical Parity Difference est de 0,0556, soit une différence absolue de 5,56 points de pourcentage. Bien que ces valeurs s'écartent légèrement de l'idéal, elles restent dans l'intervalle généralement accepté pour le Disparate Impact (entre 0,8 et 1,2). La légère sur-représentation des femmes dans les prédictions d'attrition pourrait être due à la structure même des données ou à la simplicité du modèle (profondeur 2), mais la correction a tout de même permis de réduire significativement le biais initial.

6.3.5. Synthèse et discussion

Le tableau 3 récapitule les performances obtenues après correction pour les deux attributs sensibles. On constate que la technique de Reweighting a permis d'atteindre un excellent niveau d'équité pour MaritalStatus, avec des métriques quasi idéales, tout en conservant une exactitude élevée. Pour Gender, la correction est également satisfaisante, même si un léger déséquilibre subsiste ; celui-ci pourrait être affiné par un ajustement plus poussé des hyperparamètres ou par l'utilisation de techniques post-traitements complémentaires. Globalement, ces résultats valident l'approche adoptée pour rendre le modèle de prédiction du turnover plus juste et moins discriminant, sans sacrifier excessivement la performance prédictive.

Tableau des Métriques d'équité et performance après Reconditionnement :

- **Attribut sensible :** Variable protégée (genre, situation familiale) pour laquelle on évalue l'équité.
- **Disparate Impact :** Rapport des taux de prédiction positive entre groupe défavorisé et privilégié (idéal = 1).

- **Statistical Parity Difference** : Différence des taux de prédiction positive entre groupe défavorisé et privilégié (idéal = 0).
- **Accuracy** : Taux de bonnes classifications sur l'ensemble de test.

Tableau 13: Métriques d'équité et performance après Reconditionnement

Attribut sensible	Disparate Impact	Statistical Parity Difference	Accuracy
MaritalStatus	1,0292	0,0045	0,7846
Gender	1,2017	0,0556	0,7143

La figure ci-dessous illustre graphiquement ces résultats, en superposant les métriques d'équité et l'exactitude pour chaque attribut. On y observe la nette amélioration de l'équité pour MaritalStatus et la situation acceptable pour Gender.




Figure 38: graphique des Métriques d'équité et performance

Ainsi, l'intégration d'une étape de correction par Reconditionnement dans le pipeline de modélisation permet de concilier performance prédictive et non-discrimination, répondant aux exigences éthiques et légales des systèmes RH automatisés.

7. Déploiement : Implémentation de l'Application RecrutIA

Cette partie présente l'implémentation de l'application web RecrutIA, développée comme couche de présentation du système de prédiction du risque d'attrition. Elle s'articule autour de trois composants principaux : un pipeline d'extraction intelligente des données à partir de CV au format PDF, piloté par le modèle Llama 3.3 70B via l'API Groq ; un moteur de prédiction basé sur un classificateur Random Forest entraîné sur le jeu de données IBM HR Analytics ; et une interface utilisateur moderne développée avec Streamlit en thème sombre éditorial.

7.1. Environnement et pile technologique

7.1.1. Langage et framework

L'application est entièrement écrite en Python 3.12. Le framework Streamlit a été retenu pour sa capacité à transformer un script Python en application web interactive sans nécessiter de code JavaScript ou de serveur back-end distinct. Le tableau suivant récapitule les dépendances principales.

Tableau 14 : Dépendances principales de l'application RecrutIA

Bibliothèque	Version	Rôle
streamlit	1.35+	Interface web
groq	0.9+	Client API Llama 3.3 (extraction CV)
pdfplumber	0.11+	Extraction de texte PDF
scikit-learn	1.6+	Modèle Random Forest
pandas	2.2+	Manipulation des données
plotly	5.22+	Visualisation (jauge de score)

7.2. Interface utilisateur

7.2.1. Page d'accueil et navigation

La figure 50 présente la page d'accueil de l'application. L'en-tête est structuré en trois niveaux de lecture :

1. Le titre principal « Analyse De CV par Intelligence Artificielle » en dégradé blanc-violet occupe l'espace central et ancre la promesse de valeur.
2. Un sous-titre descriptif précise le moteur utilisé (Random Forest + Llama 3.3) sans surcharger visuellement.

3. Un badge violet libellé « Deux modes d'analyse » identifie immédiatement les capacités de l'application.




Figure 39 : Page d'accueil — en-tête et sélection du mode

Deux boutons de navigation permettent de basculer entre les modes : Analyse CV (PDF) pour le mode automatique par intelligence artificielle, et Saisie Manuelle pour une saisie directe des attributs.

7.3. Mode 1 — Analyse automatique d'un CV PDF

7.3.1. Zone d'import et CV exemples




Figure 40 : Zone d'import du CV PDF avec boutons de CV exemples

La zone d'import est centrée sur la page et délimitée par une bordure en pointillés qui change de couleur au survol. Deux boutons de téléchargement sont fournis pour permettre aux

évaluateurs de tester l'application immédiatement, sans disposer de CV réel. Sous la zone d'import, trois cartes numérotées 01 / 02 / 03 résument le pipeline en trois étapes :

Import PDF → Extraction IA → Score ML.

7.3.2. Pipeline d'extraction intelligente

Lorsqu'un fichier PDF est déposé, le pipeline se déclenche automatiquement et affiche une barre de progression en temps réel. Le pipeline comporte deux étapes séquentielles :




Figure 41 : Barre de progression de l'extraction IA en temps réel

4. Extraction du texte PDF via la bibliothèque pdfplumber, qui traite à la fois le texte libre et les tableaux structurés présents dans le document.
5. Appel à l'API Groq avec le modèle Llama 3.3 70B Versatile. Un prompt système spécialisé contraint le modèle à retourner un objet JSON strict contenant les dix attributs requis par le modèle de prédiction, ainsi que des métadonnées enrichies (compétences, langues, coordonnées, score de confiance).

Le score de confiance (0–100 %) reflète l'estimation du modèle quant à la complétude et la cohérence des informations extraites. Un score inférieur à 50 % s'affiche en orange, un score supérieur à 75 % en vert.

7.3.3. Carte candidat et données extraites




Figure 42 : Carte de profil du candidat et grille des 8 métriques ML

La carte candidat présente le nom, le poste actuel, la dernière entreprise, la localisation, et les coordonnées si présentes dans le CV. Les badges de compétences (fond violet) et de langues (fond vert) sont extraits automatiquement. Le score de confiance est affiché en grand format dans le coin supérieur droit.

En dessous, une grille de 8 tuiles métriques présente de façon synthétique les valeurs transmises au modèle : Âge, Genre, Situation familiale, Formation, Expérience, Formations/an, Distance domicile-travail et Disponibilité aux déplacements.

7.3.4. Correction manuelle des données

Modifier les donnees extraites si necessaire

Age	Niveau d'Etudes
31	Bac+2 (BTS/DUT)
Genre	Annees d'experience
☒ Homme ☐ Femme	7
Situation Familiale	Formations (an dernier)
Marie(e)	3
Distance domicile-travail (km)	Deplacements pro
15	Deplacements rares

Figure 43 : Volet de correction manuelle des données extraites

Un volet expansible permet à l'utilisateur de corriger manuellement toute donnée mal extraite, avant de lancer la prédiction. Ce mécanisme est essentiel pour garantir la fiabilité de la prédiction : l'IA peut se tromper sur des éléments ambigus (age déduit, distance estimée), et l'utilisateur reste maître de la décision finale.

7.4. Mode 2 — Saisie manuelle

The screenshot shows a web form titled "INFORMATIONS DU CANDIDAT" with a dark theme. It is organized into four main sections: "PROFIL PERSONNEL", "FORMATION & EXPERIENCE", "SITUATION GEOGRAPHIQUE", and "DISPONIBILITE".

- PROFIL PERSONNEL:** Includes "Age" (input: 25), "Genre" (radio buttons: Homme selected, Femme), and "Situation familiale" (dropdown: Marie(e)).
- FORMATION & EXPERIENCE:** Includes "Niveau d'etudes" (dropdown: Bac+2 (BTS/DUT)), "Annees d'experience" (input: 5), and "Formations (annee derniere)" (slider: 2).
- SITUATION GEOGRAPHIQUE:** Includes "Distance domicile-travail (km)" (slider: 6).
- DISPONIBILITE:** Includes "Deplacements professionnels" (dropdown: Deplacements rares).

A large blue button at the bottom center is labeled "Analyser le candidat".

Figure 44 : Formulaire de saisie manuelle des attributs du candidat

Le mode formulaire permet d'alimenter directement le modèle de prédiction sans passer par l'extraction PDF. Il est organisé en quatre blocs thématiques disposés sur une grille à deux colonnes :

6. Profil personnel : âge, genre, situation familiale.
7. Formation & expérience : niveau d'études (5 niveaux de brevet à bac+5), années d'expérience totale, nombre de formations suivies l'année précédente.
8. Situation géographique : distance domicile-travail en kilomètres (curseur de 1 à 50 km).
9. Disponibilité : fréquence des déplacements professionnels (aucun, rares, fréquents).

Ce mode est particulièrement utile lors d'entretiens téléphoniques ou lorsque le candidat n'a pas encore transmis son CV au format numérique.

7.5. Affichage des résultats

Les résultats sont identiques quel que soit le mode d'entrée utilisé.

7.5.1. Bandeau de score



Figure 45 : Bandeau de score avec décision de recrutement

Le score de recrutement est défini comme le complément à 100 de la probabilité d'attrition prédite par le modèle :

$$S_{\text{recrutement}} = 100 - P(\text{attrition}) \times 100$$

La décision est seuillée en quatre catégories :

Tableau 17 : Seuils de décision et grades associés

Score	Décision	Signification	Grade
$\geq 80 \%$	Fortement recommandé	Faible risque d'attrition	A
60–79 %	Recommandé	Risque modéré	B
40–59 %	À évaluer	Réserves à vérifier	C
$< 40 \%$	Déconseillé	Risque élevé	D

Le bandeau adopte dynamiquement la couleur de fond et de texte correspondant au grade obtenu, renforçant la lisibilité immédiate.

7.5.2. Jauge et analyse des points forts / points d'attention




Figure 46 : Jauge Plotly et analyse forces/risques du profil

La page de résultats est organisée en deux colonnes de largeur égale :

- Colonne gauche — Jauge : un indicateur circulaire Plotly de type gauge+number+delta affiche le score sur une échelle 0–100, avec des zones colorées correspondant aux quatre catégories de décision. La valeur de référence est fixée à 50 % (seuil neutre).
- Colonne droite — Analyse : une liste de points forts (marqueurs verts) et de points d'attention (marqueurs orange) est générée par des règles déterministes appliquées aux attributs du candidat. Par exemple, une distance inférieure à 15 km est systématiquement identifiée comme un facteur positif de stabilité.

7.5.3. Recommandation finale



Figure 47 : Bandeau de recommandation finale avec grade

La recommandation finale synthétise en une ligne la décision et le grade sur fond coloré. Un cercle à droite affiche le grade (A, B, C ou D) en caractères Syne Bold, apportant une lecture immédiate à la manière d'une notation.

7.5.4. Analyse narrative par l'IA



Figure 48 : Analyse narrative RH générée par Llama 3.3 70B

La section finale constitue l'une des contributions originales de ce projet. Après le calcul du score ML, un second appel à l'API Groq est effectué avec un prompt contextualisant le profil complet du candidat et la décision obtenue. Le modèle produit un paragraphe de 5 à 7 phrases structuré en trois parties implicites :

10. Facteurs positifs : identification des attributs ayant contribué favorablement au score (stabilité familiale, formation, expérience, proximité géographique, etc.)
11. Facteurs de risque : mention des signaux pouvant indiquer une fragilité de l'engagement à long terme.
12. Recommandation concrète : conseil opérationnel à l'adresse du recruteur (entretien ciblé, vérification salariale, etc.)

Ce composant transforme une prédiction numérique opaque en une aide à la décision argumentée, accessible à un responsable RH non spécialiste en apprentissage automatique.

8. Conclusion

Ce chapitre a démontré qu'il est possible de concilier performance prédictive et équité algorithmique dans la modélisation de l'attrition du personnel. Après une phase exploratoire ayant mis en évidence un fort déséquilibre de classes (seulement 16 % de départs) et des disparités selon des attributs sensibles tels que la situation familiale et le genre, plusieurs techniques de rééquilibrage ont été évaluées, notamment la pondération des classes, SMOTE, SMOTETomek et SMOTEENN, ainsi que des optimisations avancées incluant GridSearchCV,

ADASYN et le `BalancedRandomForestClassifier`. Le modèle finalement retenu est une Random Forest à classes équilibrées, offrant une précision de 50 % sur la classe minoritaire avec un faible taux de faux positifs, critère essentiel dans un contexte RH où chaque alerte injustifiée peut engendrer des conséquences opérationnelles significatives. Sur le plan de l'équité, l'analyse des biais a confirmé que le modèle initial produisait des prédictions disproportionnées selon les groupes protégés. L'application de la technique de prétraitement Reweighting a permis de corriger ces disparités de manière satisfaisante, tant pour la situation familiale (Disparate Impact = 1,029 ; Statistical Parity Difference = 0,005) que pour le genre (Disparate Impact = 1,202 ; Statistical Parity Difference = 0,056), tout en maintenant une exactitude globale supérieure à 71 %. Ces résultats confirment que l'intégration de mécanismes de détection et de correction des biais dès la phase de conception est non seulement faisable, mais indispensable pour garantir un déploiement responsable et légitime des systèmes RH automatisés.

Conclusion Générale

Ce projet de recherche a permis de développer un cadre méthodologique complet pour la détection et l'atténuation des biais algorithmiques dans les modèles de prédiction du turnover, répondant à une problématique à la fois scientifique et éthique au cœur des systèmes RH automatisés. En s'appuyant sur le jeu de données IBM HR Analytics Employee Attrition, nous avons conduit une démarche rigoureuse couvrant l'intégralité du cycle de vie du modèle : exploration et prétraitement des données, sélection des variables, entraînement des classificateurs, détection des biais via AIF360, application de techniques de mitigation et déploiement d'un prototype interactif sous Streamlit.

Les résultats démontrent qu'il est possible de concilier performance prédictive et équité algorithmique sans compromis excessif. Le modèle retenu, une Random Forest à classes équilibrées, atteint une précision satisfaisante sur la classe minoritaire tout en satisfaisant les critères de fairness après application du Reweighing, avec des métriques d'équité très acceptables pour la situation familiale et le genre. Ces résultats confirment que l'intégration des contraintes d'équité dès la phase de conception est une condition de légitimité des systèmes décisionnels, non un obstacle à la performance.

Au-delà des contributions techniques, ce travail soulève des questions fondamentales sur la responsabilité des organisations dans le déploiement de l'IA en contexte RH. Dans un environnement réglementaire de plus en plus exigeant, les entreprises ne peuvent ignorer les biais structurels que leurs outils de gestion des talents sont susceptibles de reproduire ou d'amplifier. Ce projet fournit ainsi aux praticiens un cadre opérationnel concret pour auditer, corriger et documenter l'équité de leurs modèles prédictifs.

Plusieurs perspectives s'ouvrent à l'issue de ce travail. Sur le plan technique, l'exploration de techniques de mitigation plus avancées comme l'adversarial debiasing, ainsi que l'extension à d'autres attributs sensibles tels que l'âge ou l'origine. Sur le plan applicatif, l'enrichissement du prototype RecrutIA avec des fonctionnalités d'explicabilité via SHAP ou LIME renforcerait la transparence des décisions. Enfin, une validation sur des données RH réelles du contexte marocain permettrait d'adapter les recommandations aux spécificités locales du marché du travail.

Bibliographie:

- [1] J. Agassi and J. Wiezenbaum, “Computer Power and Human Reason: From Judgment to Calculation,” *Technology and Culture*, vol. 17, no. 4, p. 813, Oct. 1976, doi: 10.2307/3103715.
- [2] J. A. Mattu Jeff Larson, Lauren Kirchner, and Surya, “Machine Bias,” ProPublica. Accessed: Feb. 16, 2026. [Online]. Available: <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>
- [3] J. Dastin, “Insight - Amazon scraps secret AI recruiting tool that showed bias against women,” *Reuters*, Oct. 11, 2018. Accessed: Feb. 16, 2026. [Online]. Available: <https://www.reuters.com/article/world/insight-amazon-scraps-secret-ai-recruiting-tool-that-showed-bias-against-women-idUSKCN1MK0AG/>
- [4] N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman, and A. Galstyan, “A Survey on Bias and Fairness in Machine Learning,” *ACM Comput. Surv.*, vol. 54, no. 6, pp. 1–35, Jul. 2022, doi: 10.1145/3457607.
- [5] “Bias in algorithms – Artificial intelligence and discrimination”.
- [6] “A Framework for Understanding Sources of Harm throughout the Machine Learning Life Cycle.” Accessed: Feb. 17, 2026. [Online]. Available: https://www.researchgate.net/publication/361808470_A_Framework_for_Understanding_Sources_of_Harm_throughout_the_Machine_Learning_Life_Cycle
- [7] R. Schwartz, A. Vassilev, K. Greene, L. Perine, A. Burt, and P. Hall, “Towards a standard for identifying and managing bias in artificial intelligence,” National Institute of Standards and Technology (U.S.), Gaithersburg, MD, NIST SP 1270, Mar. 2022. doi: 10.6028/NIST.SP.1270.
- [8] “Insight - Amazon scraps secret AI recruiting tool that showed bias against women | Reuters.” Accessed: Feb. 17, 2026. [Online]. Available: <https://www.reuters.com/article/world/insight-amazon-scraps-secret-ai-recruiting-tool-that-showed-bias-against-women-idUSKCN1MK0AG/>
- [9] “Addressing Algorithmic Bias in AI-Driven HRM Systems: Implications for Strategic HRM Effectiveness - Bandara - 2025 - Human Resource Management Journal - Wiley Online Library.” Accessed: Feb. 17, 2026. [Online]. Available: <https://onlinelibrary.wiley.com/doi/10.1111/1748-8583.12609?af=R>
- [10] “Rapport de suivi de la situation économique au Maroc, Automne 2023 : De la résilience à la prospérité partagée,” World Bank. Accessed: Feb. 17, 2026. [Online]. Available: <https://www.banquemondiale.org/fr/country/morocco/publication/morocco-economic-monitor-fall-2023-from-resilience-to-shared-prosperity>
- [11] C. Dwork, M. Hardt, T. Pitassi, O. Reingold, and R. Zemel, “Fairness Through Awareness,” Nov. 29, 2011, *arXiv*: arXiv:1104.3913. doi: 10.48550/arXiv.1104.3913.
- [12] R. Zemel, “Learning Fair Representations”.

- [13] M. Hardt, E. Price, and N. Srebro, "Equality of Opportunity in Supervised Learning," in *Advances in Neural Information Processing Systems*, Curran Associates, Inc., 2016. Accessed: Feb. 15, 2026. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2016/hash/6a9659feb1216f14f7384ba499518b38-Abstract.html
- [14] M. Raghavan, S. Barocas, J. Kleinberg, and K. Levy, "Mitigating bias in algorithmic hiring: evaluating claims and practices," in *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*, in FAT* '20. New York, NY, USA: Association for Computing Machinery, Jan. 2020, pp. 469–481. doi: 10.1145/3351095.3372828.
- [15] I. A. Oladipupo, S. A. Folorunso, S. O. Balogun, F. I. Suleiman, O. C. Olayemi, and J. M. Jacob, "Bias and Fairness in AI-Based Employee Attrition Prediction Using Random Forest," *Innov. Comput. Data Sci.*, vol. 2, no. 1, pp. 11–23, Jan. 2026, doi: 10.64389/icds.2026.02162.
- [16] C. Rigotti and E. Fosch-Villaronga, "Fairness, AI & recruitment," *Computer Law & Security Review*, vol. 53, p. 105966, Jul. 2024, doi: 10.1016/j.clsr.2024.105966.
- [17] X. Chang, "Gender Bias in Hiring: An Analysis of the Impact of Amazon's Recruiting Algorithm," *Advances in Economics, Management and Political Sciences*, vol. 23, pp. 134–140, Sep. 2023, doi: 10.54254/2754-1169/23/20230367.